

REDES NEURONAIS ARTIFICIAIS

Luís Morgado

ISEL-DEETC


REDES NEURONAIS ARTIFICIAIS

CONTEXTO HISTÓRICO

- **Surgimento na década de 40** - tecnologia com cerca de 80 anos
- **1943**: Modelo de neurónio proposto por McCulloch e Pitts, com a capacidade de distinguir entre duas categorias distintas de valores de entrada
 - No início modelos simples, com capacidade de associar um valor de saída a um conjunto de valores de entrada através de uma função linear
- **1958**: Frank Rosenblatt propõe um modelo linear designado *Perceptrão*, o primeiro neurónio artificial com capacidade de aprendizagem
- **1969**: Minsky e Papert apresentam as limitações associadas ao *Perceptrão*, estas limitações levam a uma diminuição do entusiasmo no estudo e desenvolvimento de redes neuronais artificiais
- **1986**: Rumelhart apresenta um método de treino de redes multicamada, baseado no conceito de retropropagação e propõe o conceito de connexionismo – ênfase na capacidade de processamento massivamente distribuído das redes neuronais
- **Década de 90**: Retomar do interesse no estudo e desenvolvimento de redes neuronais artificiais
- **Após 2000**: Avanços determinantes nas tecnologias de redes neuronais artificiais, com o surgimento do conceito de aprendizagem profunda (*Deep Learning*)

MODELO DE NEURÓNIO

Modelo simplificado de neurónio biológico



Dendrites - Responsáveis por receber informação de outros neurónios



Soma - Corpo do neurónio, responsável por processar a informação recebida a partir das dendrites e produzir um resultado na forma de impulsos eléctricos

Axónio - Responsável por transmitir o resultado produzido

Sinapse - Ponto de ligação do neurónio às dendrites de outros neurónios

MODELO DE NEURÓNIO

Modelo simplificado de neurónio biológico




[Munakata, 1998]

As sinapses controlam a influência que a saída de um neurónio tem sobre outro neurónio, através da permeabilidade à passagem do impulso eléctrico

A variabilidade da permeabilidade de cada sinapse é determinante para a aprendizagem



MODELO DE NEURÓNIO ARTIFICIAL



De forma simplificada, um neurónio pode ser representado por um conjunto de entradas x_i , em que cada entrada possui um peso associado w_i , representando a permeabilidade da sinapse, sendo a soma ponderada das entradas pelos pesos aplicada a uma função de activação φ , a qual determina se é produzida resposta

MODELO DE NEURÓNIO ARTIFICIAL

Perceptrão (Rosenblatt, 1957)




x_i : Entrada i w_j : Peso j

- Valores de entrada binários (podem ser resultantes de uma combinação de entradas através de uma função lógica)
- Valor de saída binário

MODELO DE NEURÓNIO ARTIFICIAL


Interpretação geométrica

Recta



$$ax + by + c = 0$$

Plano




$$ax + by + cz + d = 0$$

Hiperplano

$$a_1x_1 + a_2x_2 + \cdots + a_nx_n + b = 0$$


DEFINIÇÃO DE FUNÇÕES BOOLEANAS

Disjunção (*OR*)



True ● = +1

False ● = -1



Exemplo:

$$w_1 = 1, w_2 = 1, b = 1$$

Conjunção (*AND*)


Exemplo:

$$w_1 = 1, w_2 = 1, b = -1$$

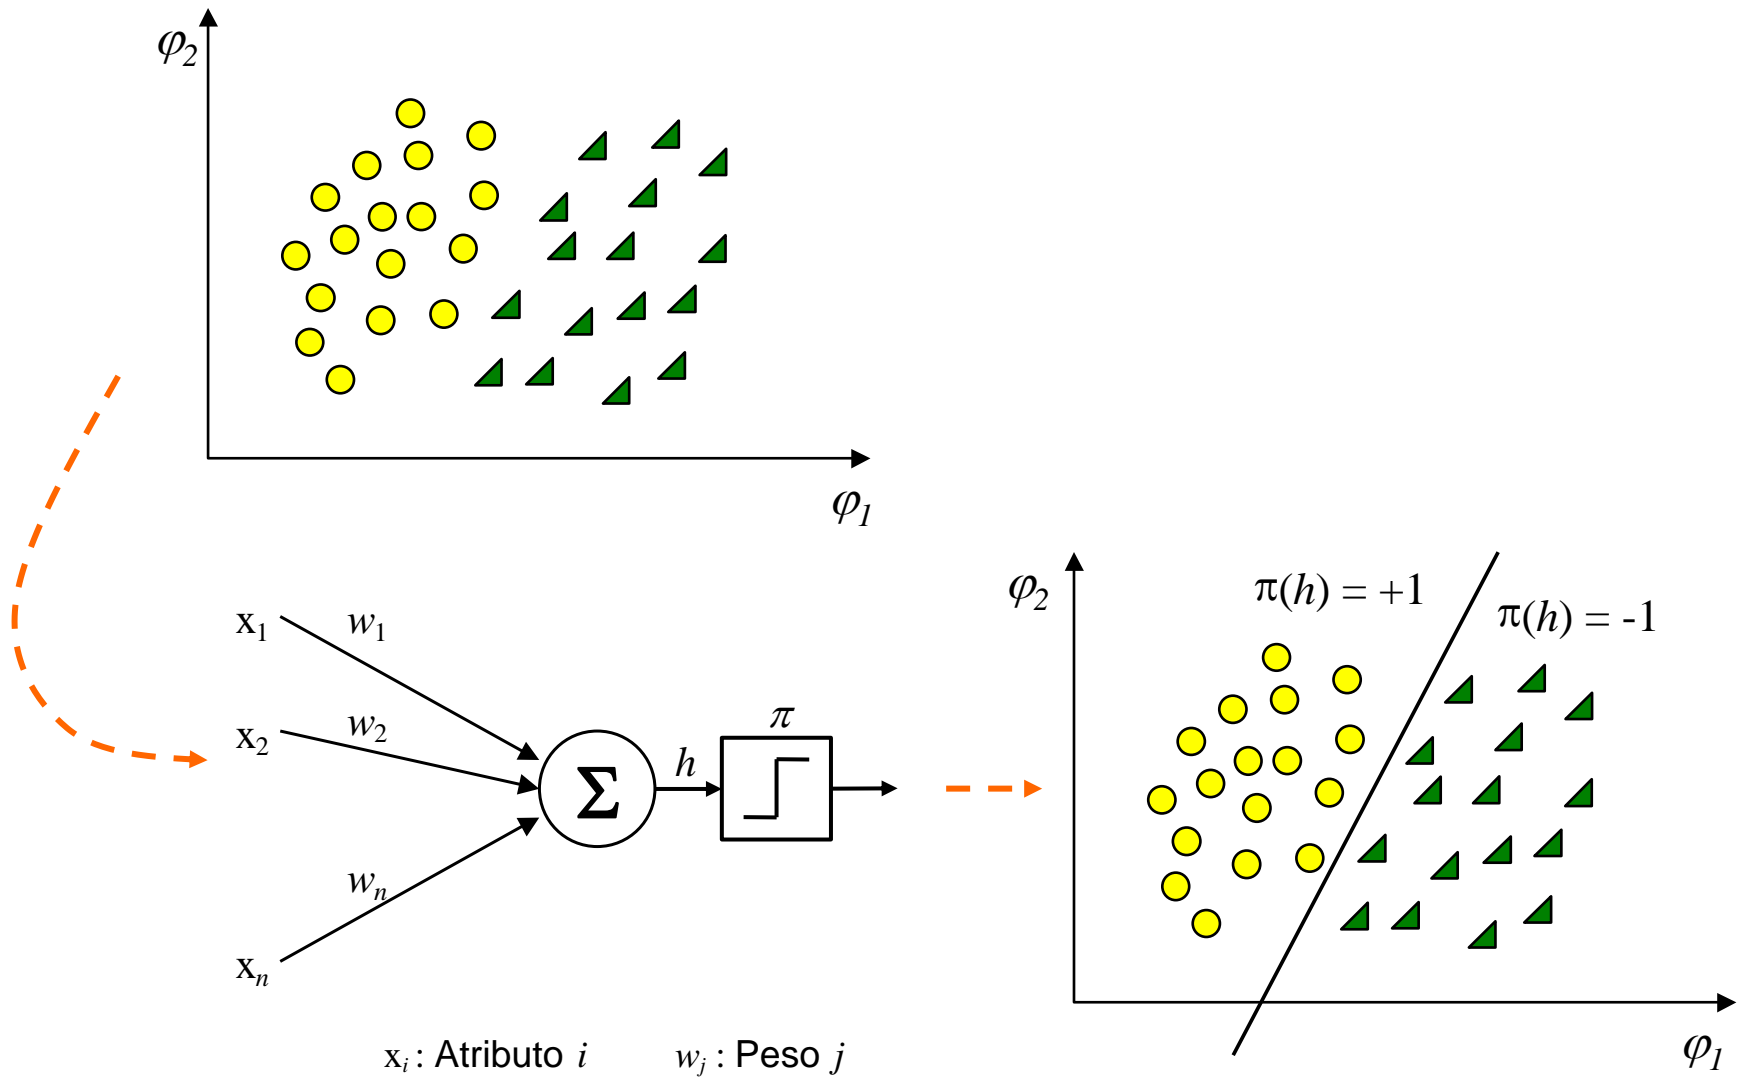
CAPACIDADE COMPUTACIONAL

SEPARABILIDADE LINEAR

- Um **problema é linearmente separável** se existirem pesos w_i e pendor b que definam uma fronteira linear entre a região da resposta excitadora e a região da resposta inibitória.
- O **perceptrão** permite resolver problemas linearmente separáveis





SEPARABILIDADE LINEAR



DEFINIÇÃO DE FUNÇÕES BOOLEANAS

Disjunção exclusiva (*XOR*)


















?

SEPARABILIDADE NÃO-LINEAR


Dados de entrada

Respostas de diferentes tipos de algoritmos de aprendizagem



REDES NEURONAIS MULTI-CAMADA

- Separabilidade de regiões





Transformação do espaço de entrada em espaços de dimensões superiores onde é possível a separação linear de regiões

Essa transformação pode ser realizada através de **redes neurais multi-camada**



DEFINIÇÃO DE REGIÕES NÃO CONVEXAS

Rede de uma camada





DEFINIÇÃO DE REGIÕES NÃO CONVEXAS

Rede de duas camadas



DEFINIÇÃO DE REGIÕES GERAIS


Rede de três camadas



Forma normal disjuntiva

Permite representar qualquer função booleana

REDES NEURONAIS MULTI-CAMADA



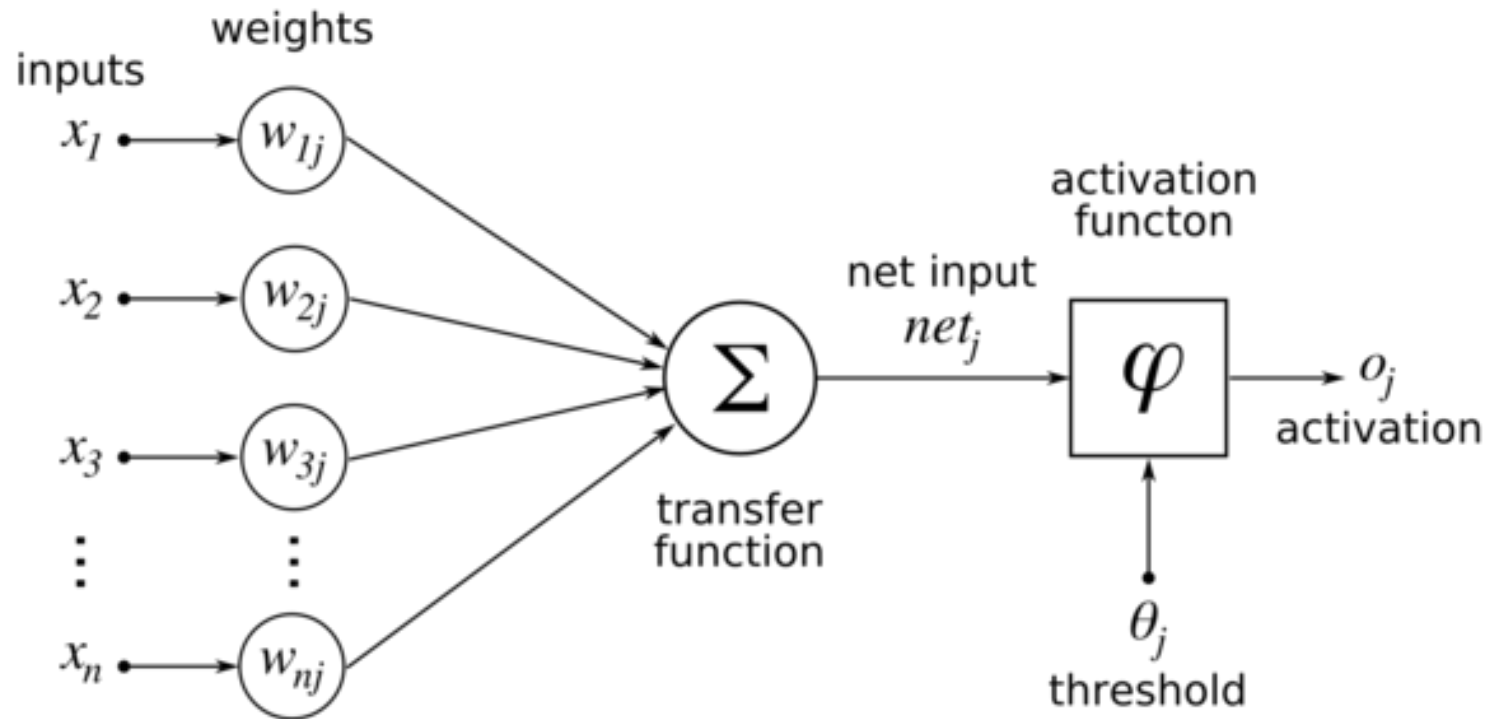
Teorema da aproximação universal

Uma rede *feed-forward* com uma única camada escondida e com um número finito de neurónios (**perceptrão multicamada**), pode aproximar funções contínuas em subconjuntos compactos de \mathbb{R}^n

Na camada escondida a rede forma uma representação distribuída das principais características dos dados → abstracção → generalização


MODELO DE NEURÓNIO ARTIFICIAL

Modelo geral de neurónio artificial





MODELO DE NEURÓNIO ARTIFICIAL

Limiar de activação (*Threshold*) vs. Pendor (*Bias*)








[Winston, 1992]



[Aggarwal, 2018]

APRENDIZAGEM EM REDES NEURONAIS

TIPOS DE FUNÇÕES DE ACTIVAÇÃO



BIBLIOGRAFIA

[Aggarwal, 2018]

C. Aggarwal, *Neural Networks and Deep Learning*
Springer, 2018

[Munakata, 1998]

T. Munakata, *Fundamentals of the New Artificial Intelligence*, Springer, 1998

[Winston, 1992]

P. Winston, *Artificial Intelligence*, 3rd Edition, Addison-Wesley, 1992

[Raizer *et al.*, 2009]

K. Raizer, H. Idagawa, E. Nobrega, L. Ferreira, *Training and Applying a Feedforward Multilayer Neural Network in GPU*, CILAMCE, 2009

[R. Gutierrez-Osuna, 2005]

R. Gutierrez-Osuna, *Introduction to Pattern Analysis*, Texas A&M University, 2005