APRENDIZAGEM POR REFORÇO

Luís Morgado

ISEL-DEETC

EXPLORAÇÃO vs. APROVEITAMENTO

- Duas vertentes da aprendizagem:
  - **EXPLORAÇÃO** (*explore*)
    - Tem por objectivo explorar todos os estados possíveis, tentando todas as acções
    - Obtenção de experiência
  - **APROVEITAMENTO** (*exploit*)
    - Utiliza o conhecimento resultante da aprendizagem para obter o máximo de recompensa
    - Restringe-se às acções que se conhece serem favoráveis

EXPLORAÇÃO vs. APROVEITAMENTO

- Estimativas de valor de uma acção a
  - $Q_t(a) \approx Q^*(a)$
- Acção de aproveitamento (*greedy*)
  - $a^*_t = \mathrm{argmax}_a[Q_t(a)]$
- Aproveitamento
  - $a_t = a^*_t$
- Exploração
  - $a_t \neq a^*_t$

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

- **Estratégia *greedy***

$$a_t = a^*_t = \text{argmax}_a\, Q_t(a)$$

- **Estratégia ε-*greedy***

$$a_t = \begin{cases} a^*_t \text{ com probabilidade } 1 - \varepsilon \\ \text{acção aleatória com probabilidade } \varepsilon \end{cases}$$

  – Balanceamento de *exploração* vs. *aproveitamento*

2.3 The 10-armed Testbed

To roughly assess the relative effectiveness of the greedy and ε-greedy action-value methods, we compared them numerically on a suite of test problems. This was a set of 2000 randomly generated k-armed bandit problems with $k = 10$. For each bandit problem, such as the one shown in Figure 2.1, the action values, $q_*(a)$, $a = 1, \ldots, 10$,

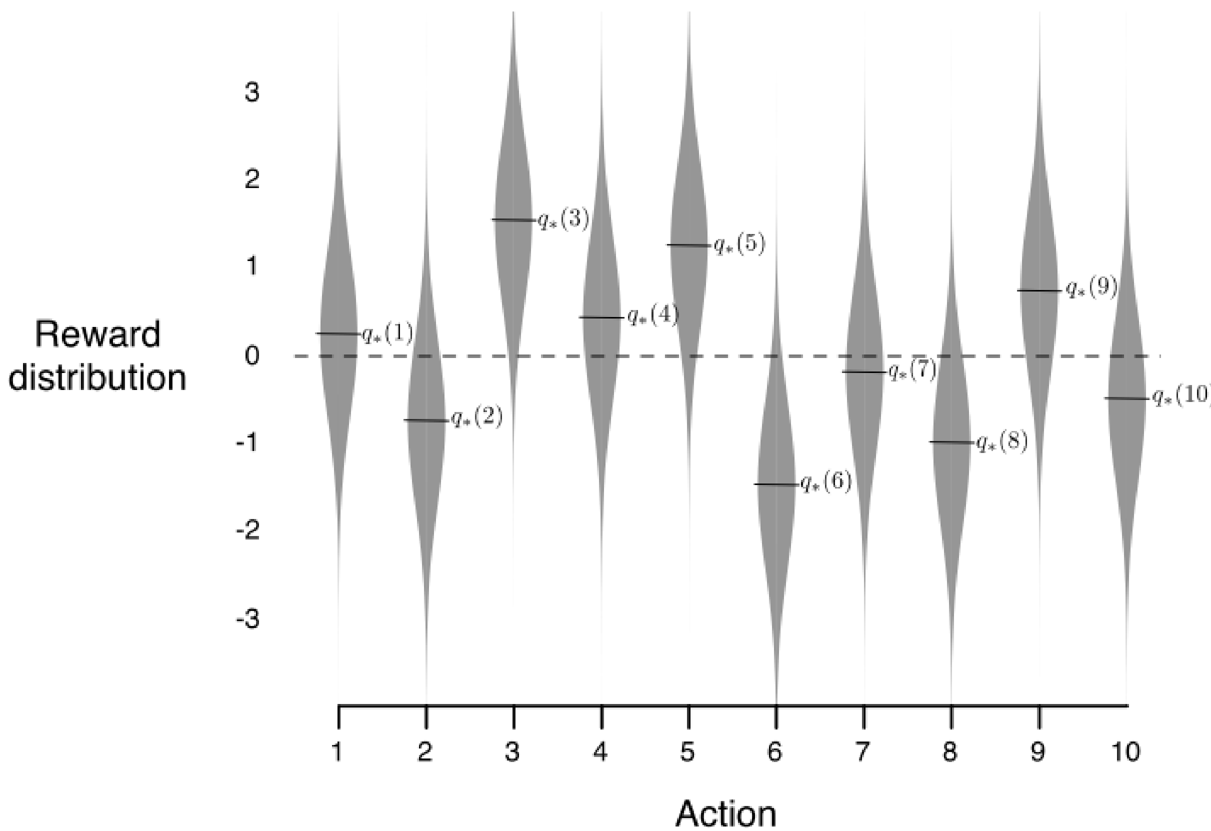

Figure 2.1: An example bandit problem from the 10-armed testbed. The true value $q_*(a)$ of each of the ten actions was selected according to a normal distribution with mean zero and unit variance, and then the actual rewards were selected according to a mean $q_*(a)$, unit-variance normal distribution, as suggested by these gray distributions.

[Sutton & Barto, 2020]

Exemplo

[Koppula, 2020]

Exemplo

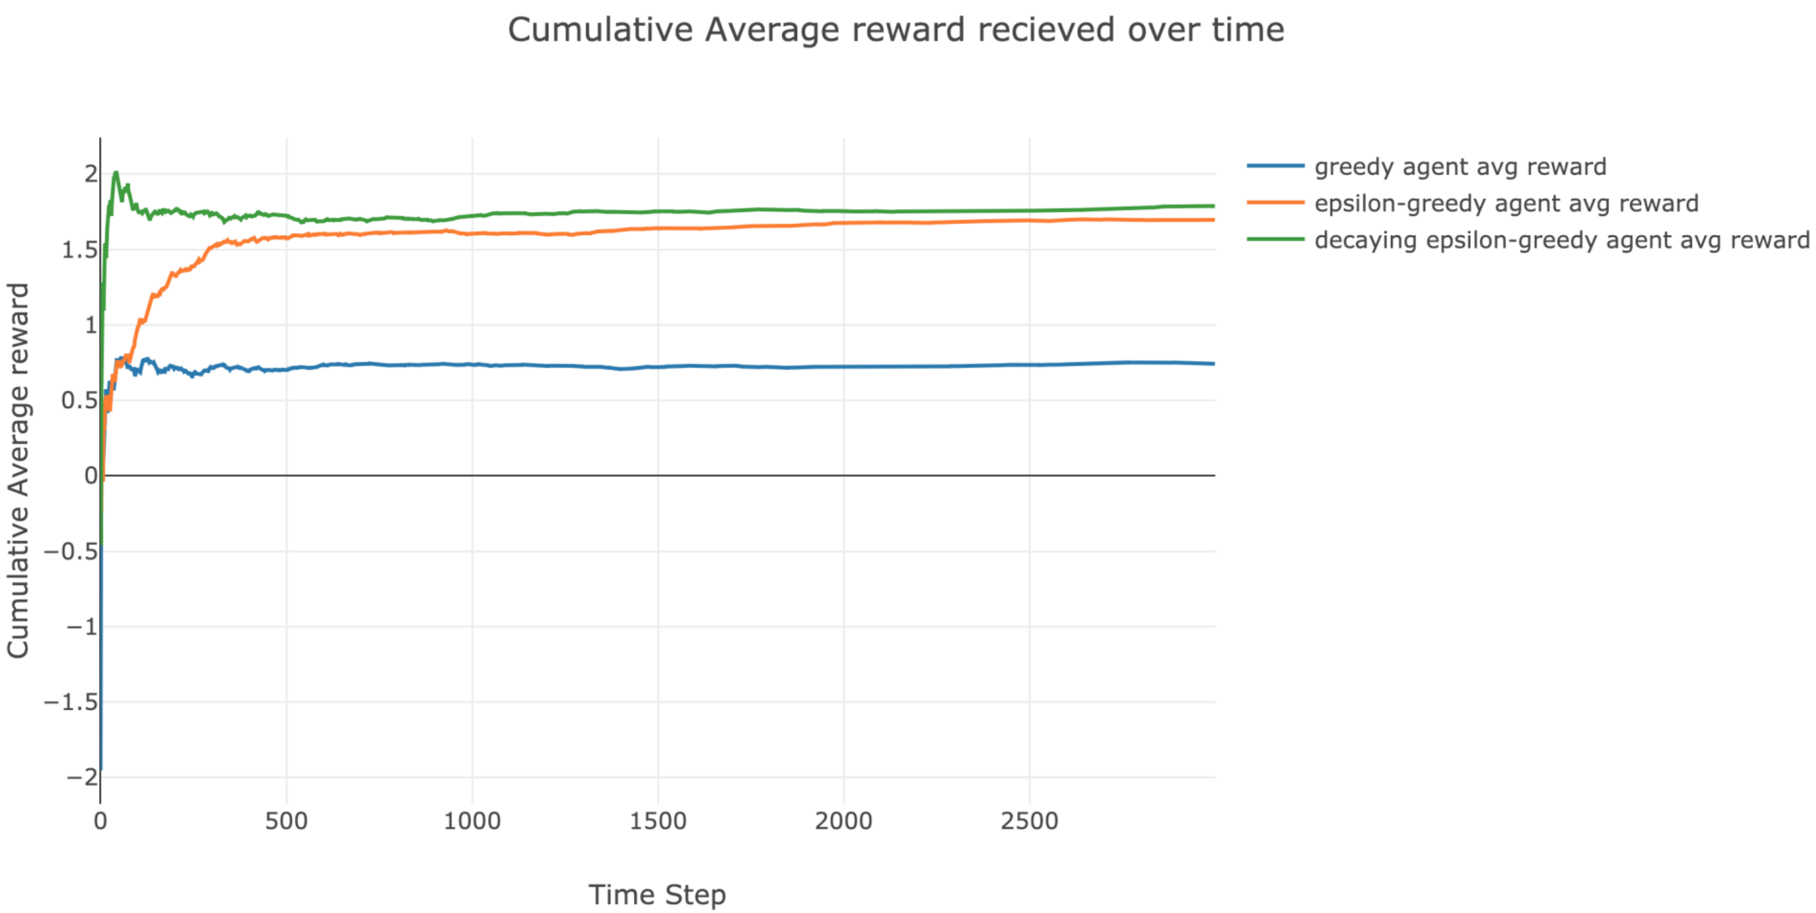

[Koppula, 2020]

Exemplo

[Koppula, 2020]

Exemplo

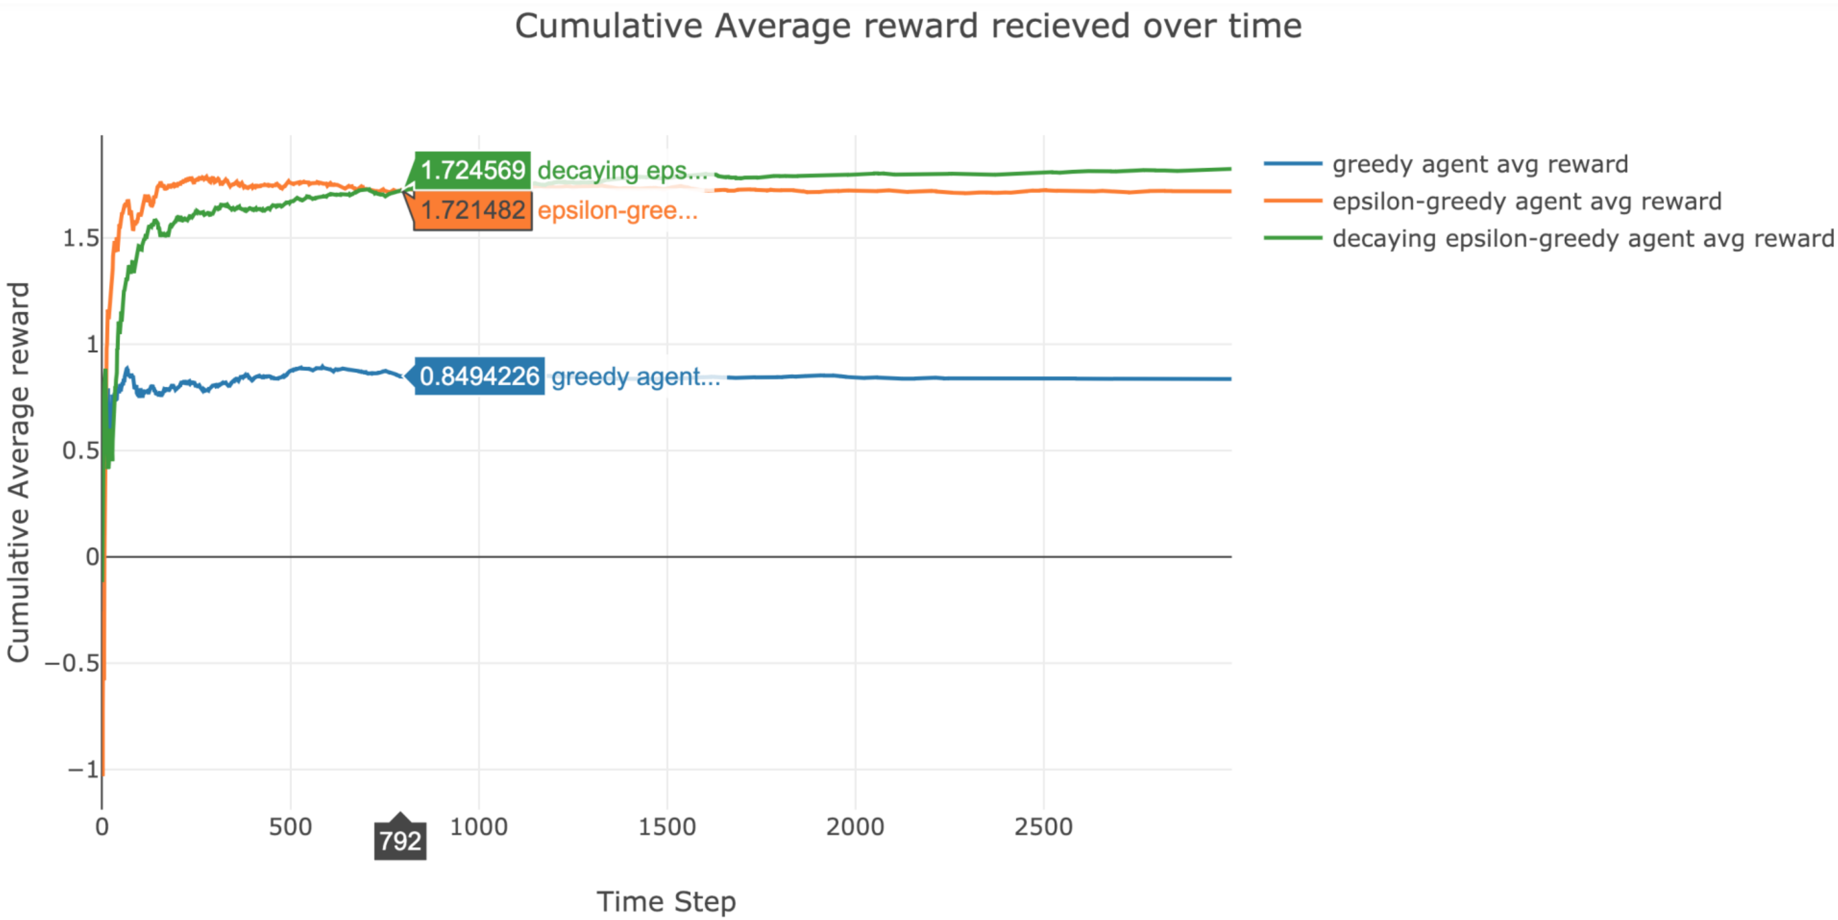

[Koppula, 2020]

Exemplo

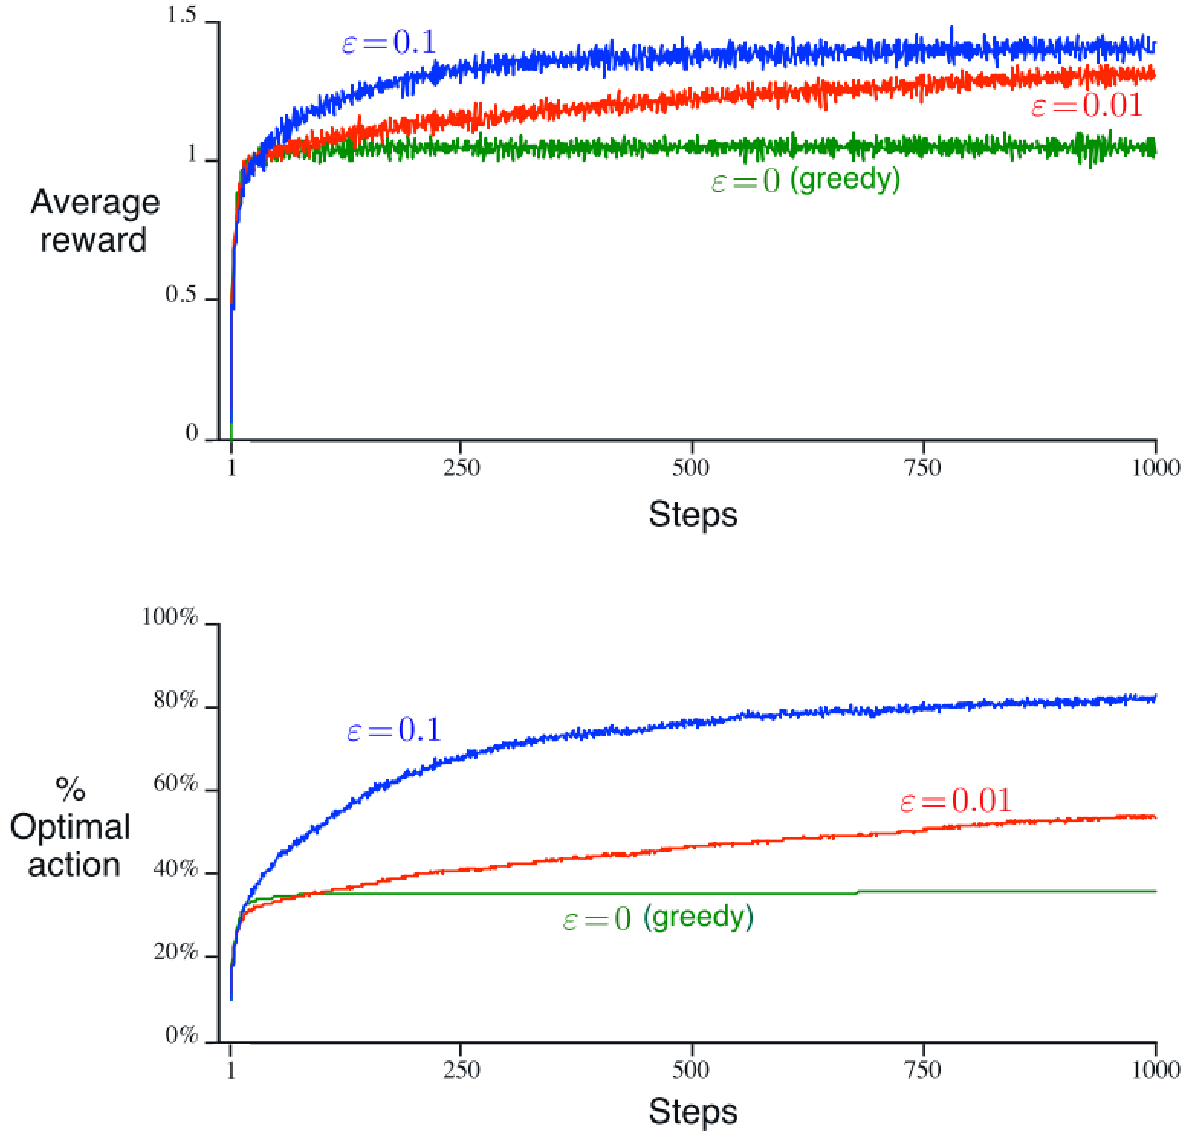

[Sutton & Barto, 2020]

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Valores iniciais optimistas

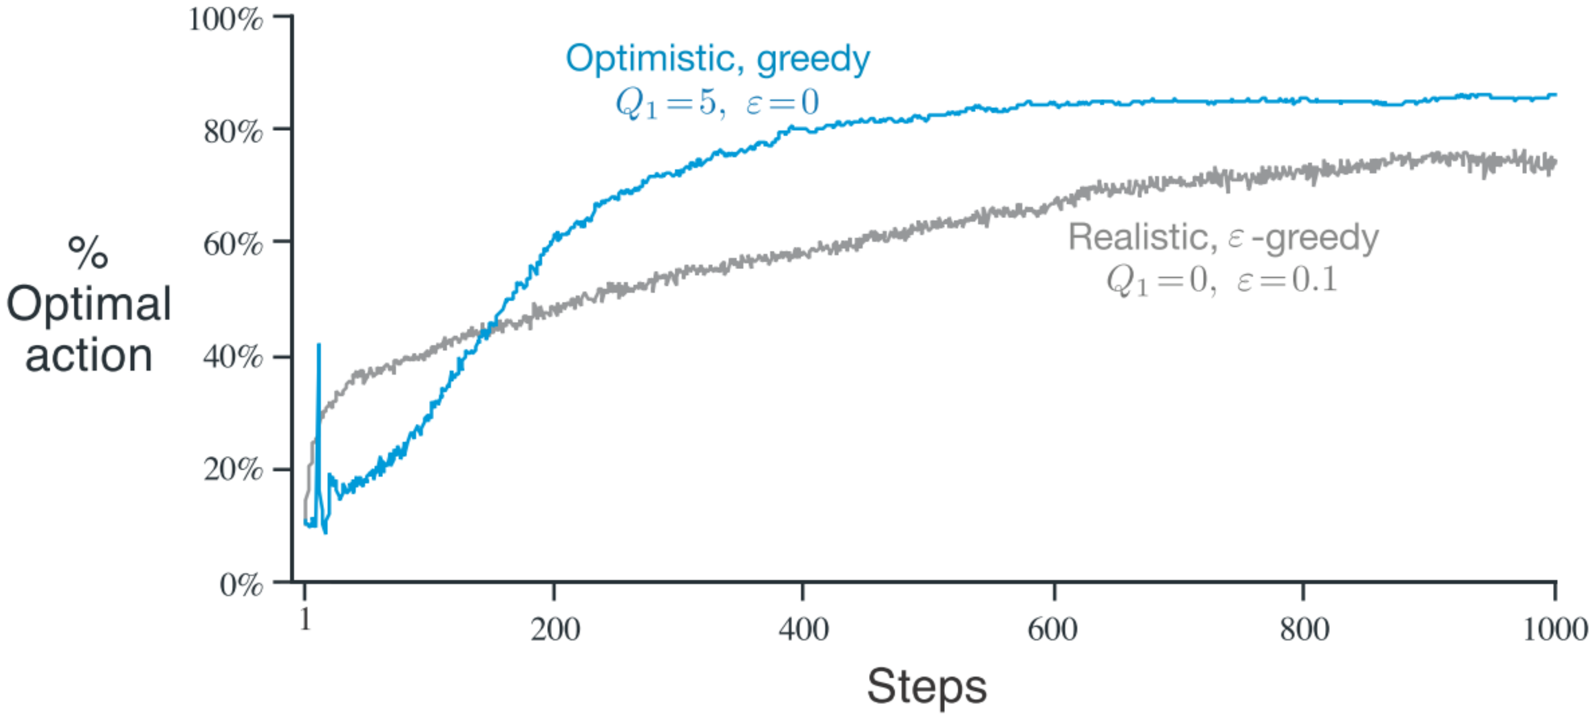

[Sutton & Barto, 2020]

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Upper Confidence Bounds (UCB)

$$A_t \doteq \underset{a}{\arg\max} \left[Q_t(a) + c\sqrt{\frac{\ln t}{N_t(a)}} \right]$$

$N_t(a)$ denotes the number of times that action a has been selected prior to time t

If $N_t(a) = 0$, then a is considered to be a maximizing action

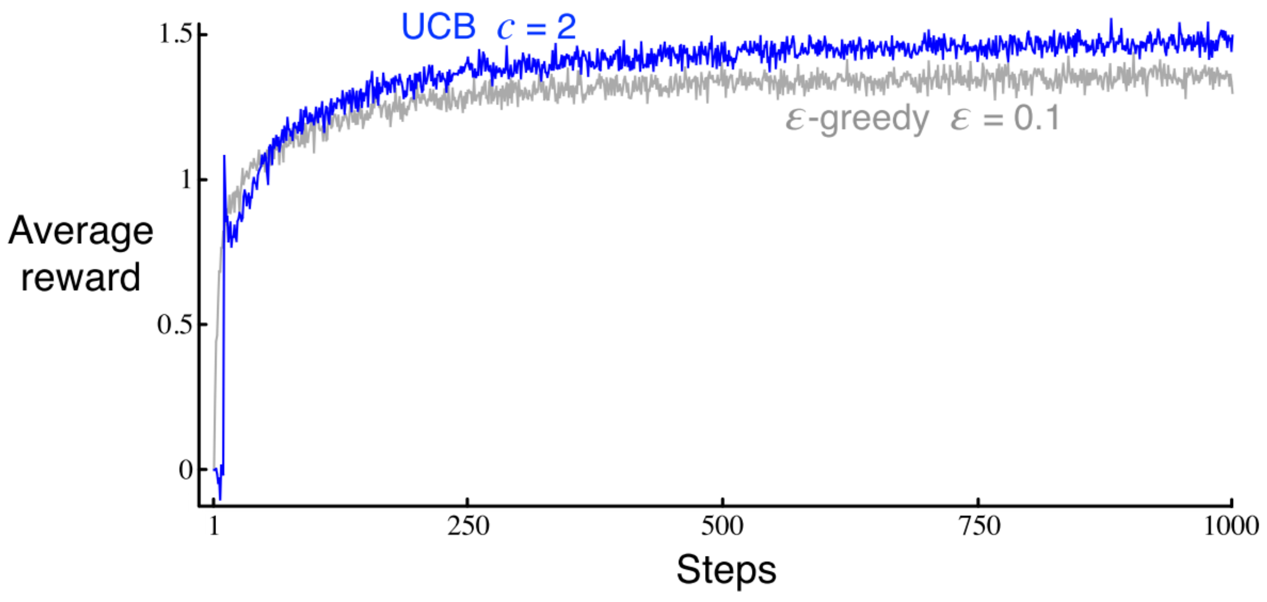

[Sutton & Barto, 2020]

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Upper Confidence Bounds (UCB)

$$A_t \doteq \underset{a}{\arg\max} \left[Q_t(a) + c\sqrt{\frac{\ln t}{N_t(a)}} \right]$$

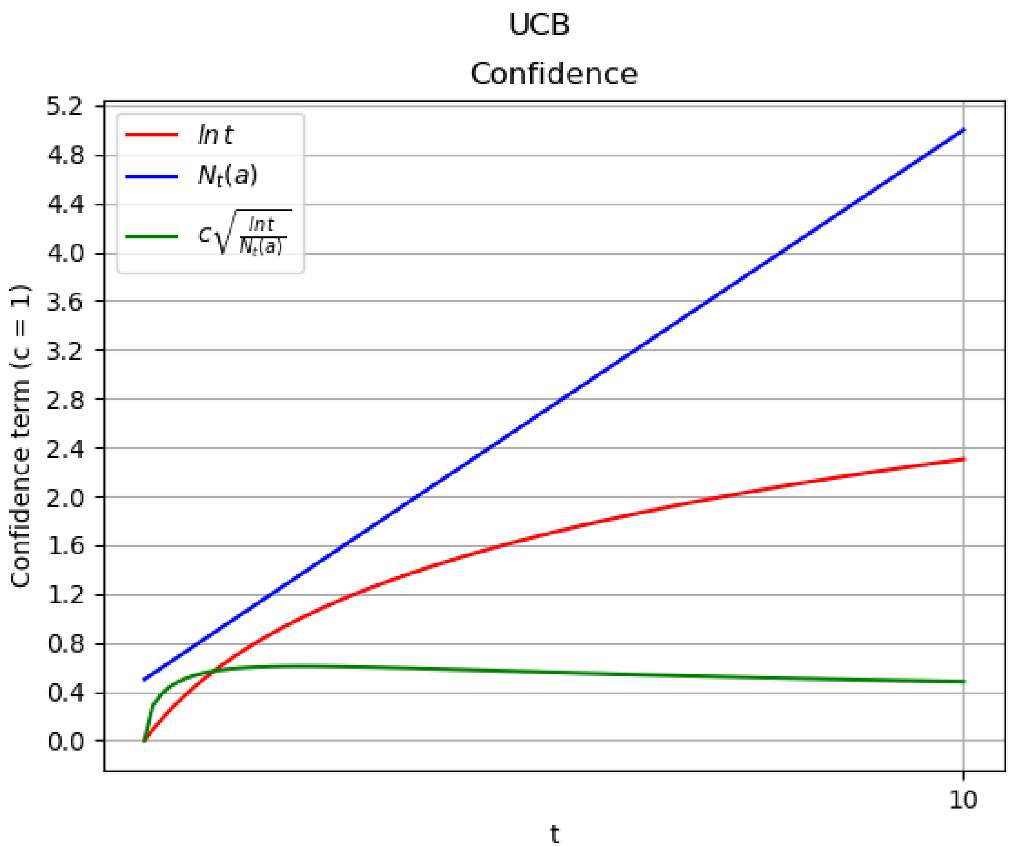

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Upper Confidence Bounds (UCB)

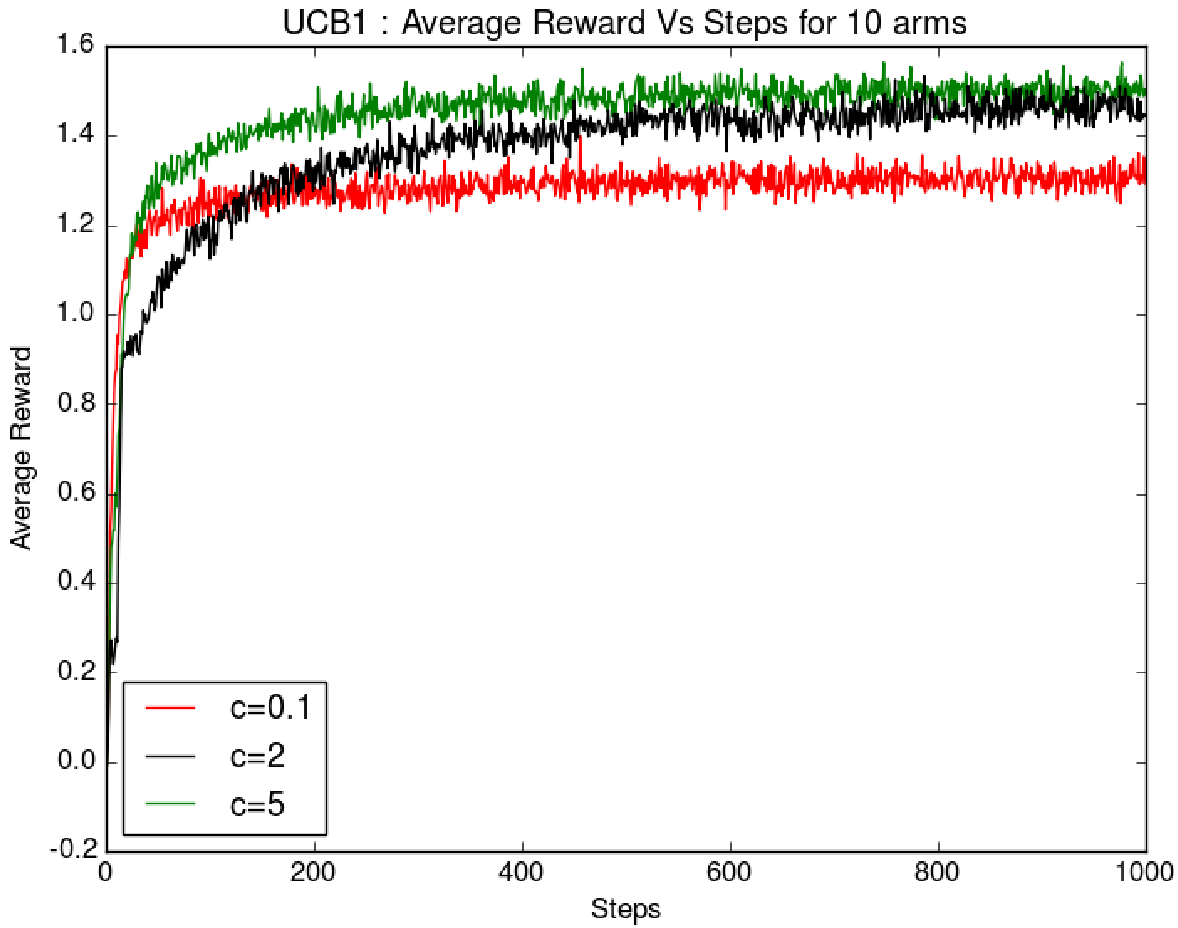

[Ramnath, 2020]

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Distribuição *Soft-max*

$$\Pr\{A_t = a\} \doteq \frac{e^{H_t(a)}}{\sum_{b=1}^{k} e^{H_t(b)}}$$

$H_t(a) \in \mathbb{R}$ numerical *preference* for each action a

$$H_t(a) = Q_t(a)/\tau$$

$$\Pr\{A_t = a\} = \frac{e^{Q_t(a)/\tau}}{\sum_{b=1}^{k} e^{Q_t(b)/\tau}}$$

τ is a positive parameter called the *temperature*

In the limit as $\tau \to 0$ softmax action selection becomes the same as greedy action selection

[Sutton & Barto, 1998, 2020]

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Distribuição *Soft-max*

$$\Pr\{A_t = a\} = \frac{e^{Q_t(a)/\tau}}{\sum_{b=1}^{k} e^{Q_t(b)/\tau}}$$

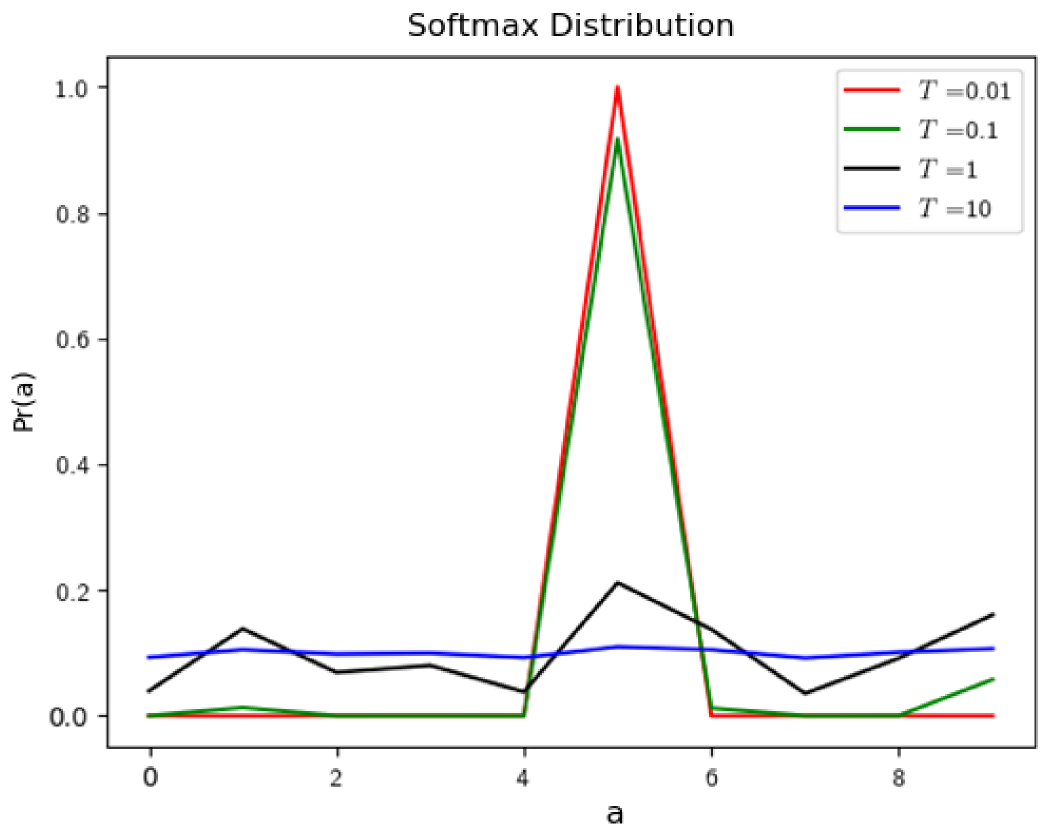

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Distribuição *Soft-max*

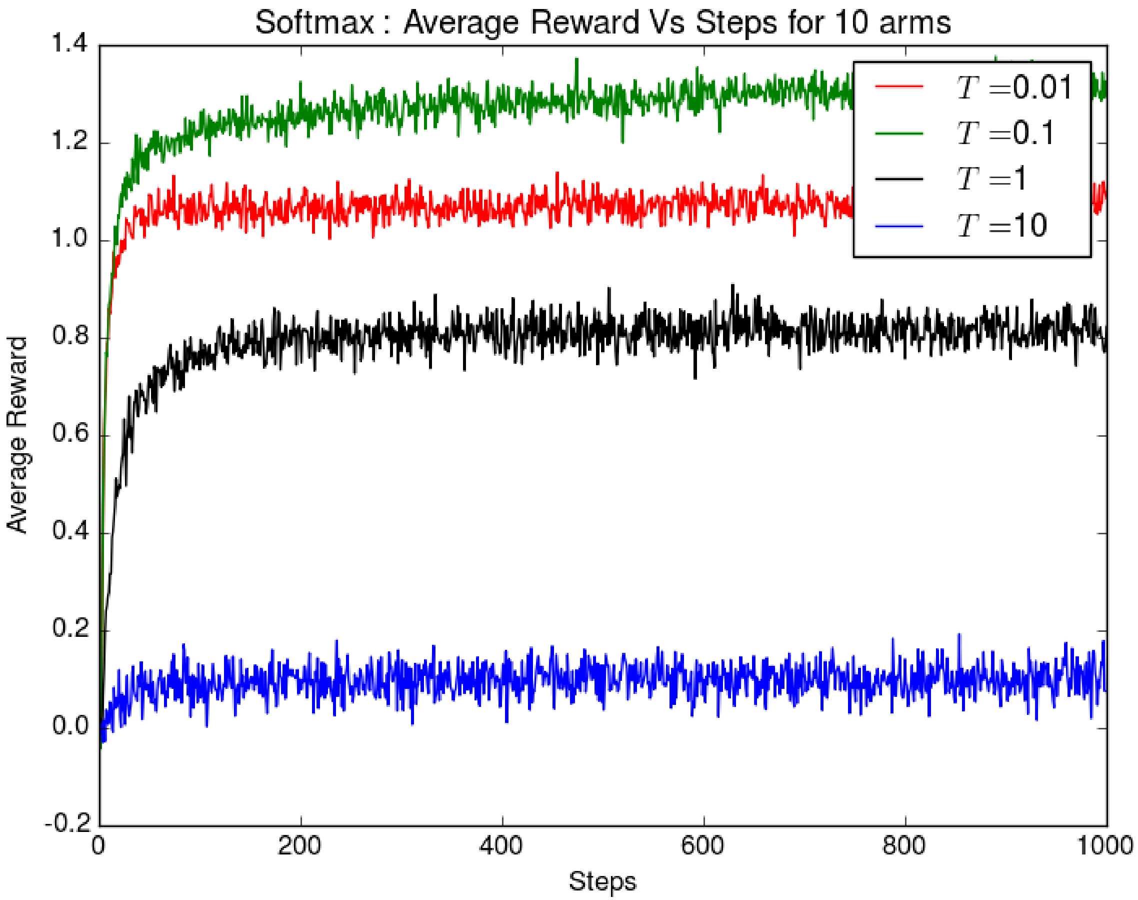

[Ramnath, 2020]

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

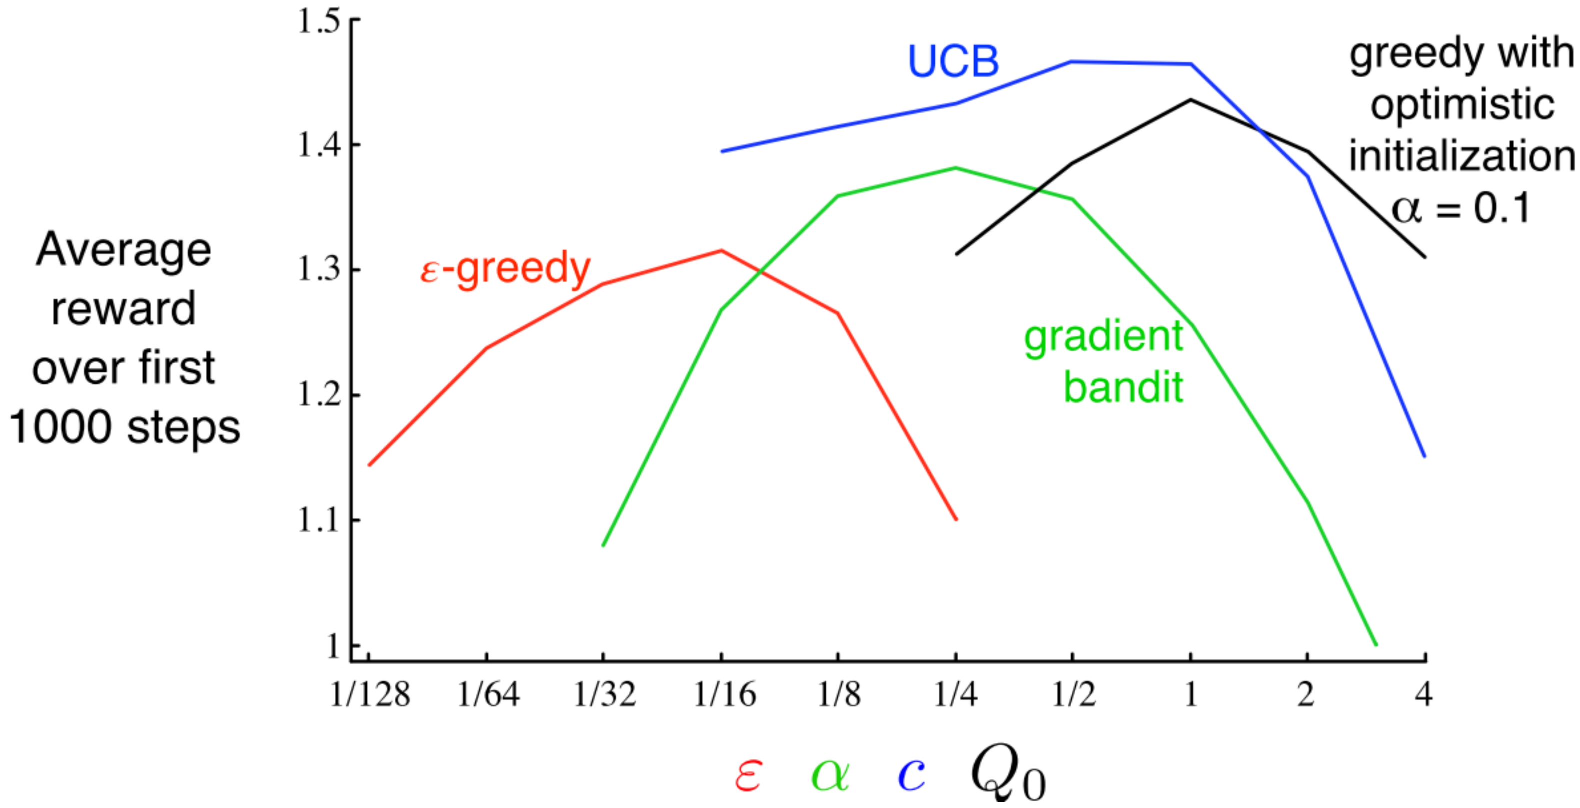

[Sutton & Barto, 2020]

APRENDIZAGEM ASSOCIATIVA

- Estado pode evoluir ao longo do tempo
  - Estados observados
    - $\boldsymbol{s} \in \boldsymbol{S}$
  - Acções realizadas
    - $\boldsymbol{a} \in \boldsymbol{A}$
  - Reforços obtidos
    - $\boldsymbol{r} \in \mathbb{R}$
  - **Valor de num estado realizar uma acção**
    - $\boldsymbol{Q(s,a)}$

APRENDIZAGEM POR REFORÇO

- Aprendizagem a partir da **interacção** com o ambiente
  - **Acção**
  - **Estado**
  - **Reforço**
    - Ganho / perda

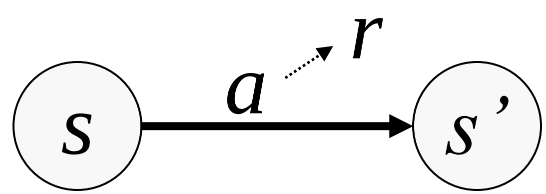

- Aprendizagem de **comportamentos**
  - O que fazer
  - Relação entre situações e acções

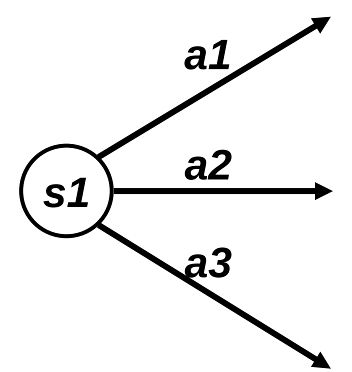

APRENDIZAGEM POR REFORÇO

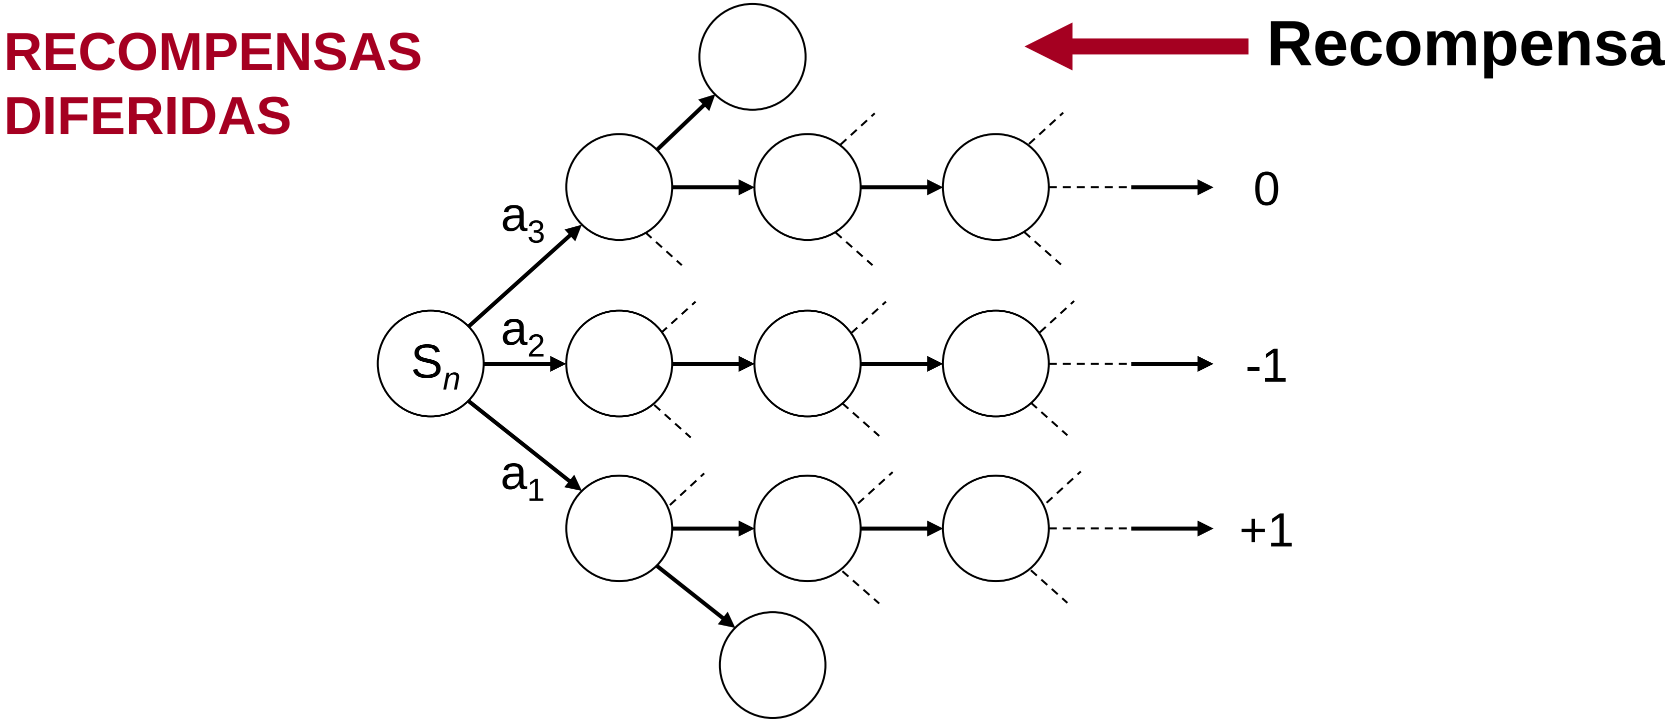

- Aprendizagem incremental a partir da experiência

$$s \rightarrow a \rightarrow r \rightarrow s' \rightarrow a' \rightarrow \ldots$$

APRENDIZAGEM POR REFORÇO

MECANISMO DE APRENDIZAGEM

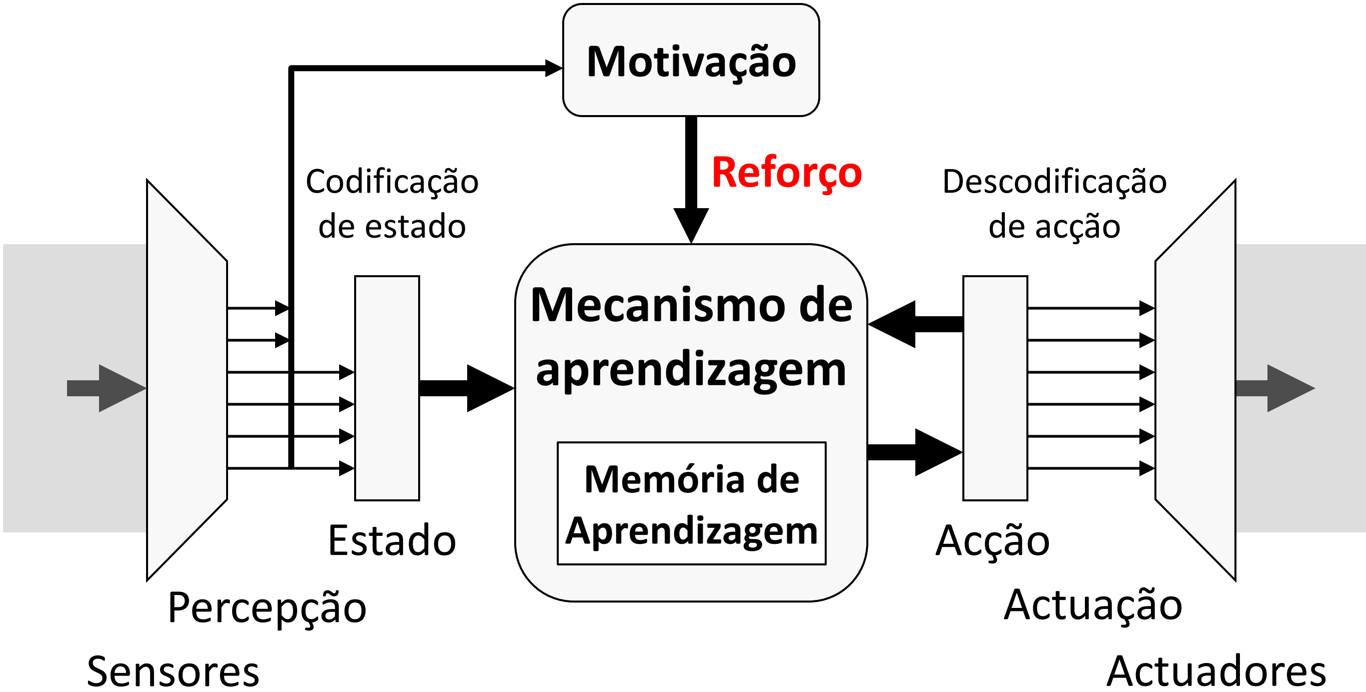

REFERÊNCIAS

[Sutton & Barto, 2020]

R. Sutton, A. Barto, “Reinforcement Learning: An Introduction”, 2nd Edition, MIT Press, 2020

[Poole & Mackworth, 2010]

D. Poole, A. Mackworth, Artificial Intelligence: Foundations of Computational Agents, Cambridge University Press, 2010

[Barnard, 2003]

C. Barnard, “Animal Behaviour: Mechanism, Development, Ecology and Evolution”, Prentice Hall, 2003

[Koppula, 2020]

R. Koppula, “Exploration vs. Exploitation In Reinforcement Learning”, *https://www.manifold.ai/exploration-vs-exploitation-in-reinforcement-learning*, 2020