APRENDIZAGEM POR REFORÇO

Luís Morgado

ISEL-DEETC

PROCESSO DE APRENDIZAGEM

- Memória de pares **estado-acção**
  - Regras (reacções) **estímulo - resposta**
- Valorização
  - **Valor** associado ao par **estado-acção**
  - $Q(s,a)$
- Aprendizagem incremental a partir da experiência

  $s \rightarrow a \rightarrow r \rightarrow s' \rightarrow a'$

RECOMPENSA E RETORNO

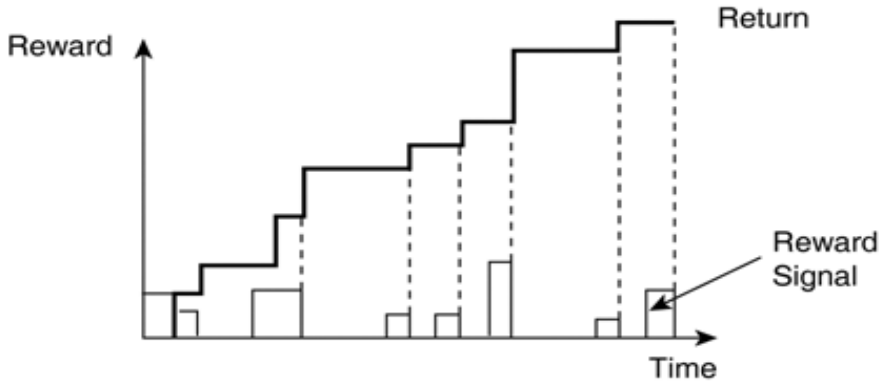

ACUMULAÇÃO

HORIZONTE FINITO

$$R_t = r_{t+1} + r_{t+2} + \ldots + r_{t+n} = \sum_{i=0}^{n} r_{t+i}$$

HORIZONTE INFINITO

$$R_t = \lim_{n\to\infty}\left(\frac{1}{n}\sum_{i=1}^{n} r_{t+i}\right)$$

HORIZONTE INFINITO COM DESCONTO TEMPORAL

$$R_t = r_{t+1} + \gamma \cdot r_{t+2} + \gamma^2 \cdot r_{t+3} + \gamma^3 \cdot r_{t+4} + \ldots = \sum_{i=1}^{\infty} \gamma^{i-1} \cdot r_{t+i}$$

$\gamma \in [0,1]$ - Factor de desconto

APRENDIZAGEM POR DIFERENÇA TEMPORAL

Actualização de uma **estimativa** de valor de **estado-acção** com base na **mudança** desse valor (diferença temporal) entre instantes sucessivos

$$NewEstimate \leftarrow OldEstimate + StepSize \left[Target - OldEstimate \right]$$

$$Q_{n+1} = Q_n + \alpha \left[R_n - Q_n \right]$$

$$Q(s,a) \leftarrow Q(s,a) + \alpha [R - Q(s,a)]$$

?

Valor de realizar uma acção a num estado s

***Valor Estado-Acção*: $Q(s,a)$**

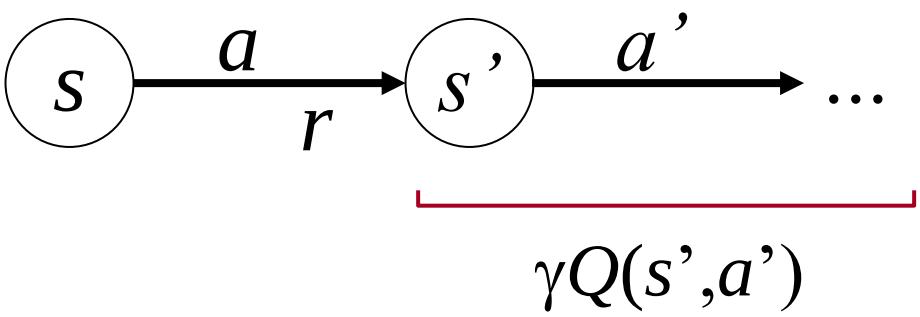

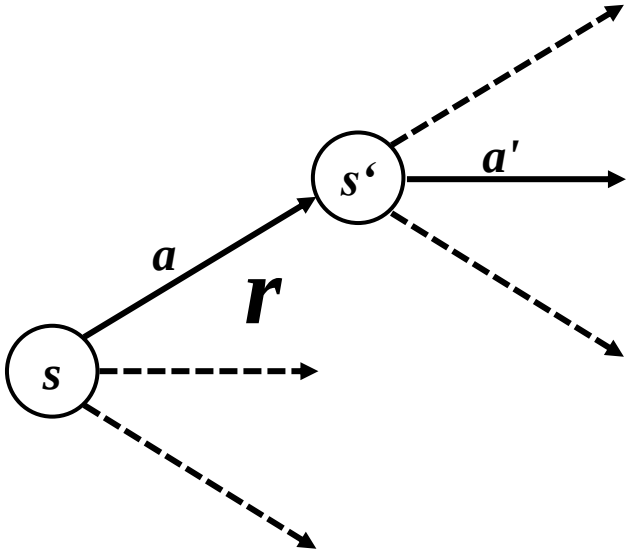

Reforço

$$R = r + \gamma Q(s',a')$$

Estimativa actual de R

APRENDIZAGEM POR DIFERENÇA TEMPORAL

Actualização de uma **estimativa** de valor de **estado-acção** com base na **mudança** desse valor (diferença temporal) entre instantes sucessivos

$$Q(s,a) \leftarrow Q(s,a) + \alpha[R - Q(s,a)]$$

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma Q(s',a') - Q(s,a)]$$

Reforço

Estimativa de R

Diferença temporal

ALGORITMO *SARSA*

Controlo de aprendizagem *On-Policy*

- Utilização da mesma política para acção e aprendizagem
- Exploração de todas as acções (políticas ε-*greedy*, ε-*soft*)

Initialize $Q(s, a)$ arbitrarily
Repeat (for each episode):
    Initialize s
    Choose a from s using policy derived from Q (e.g., ε-greedy)
    Repeat (for each step of episode):
        Take action a, observe r, s'
        Choose a' from s' using policy derived from Q (e.g., ε-greedy)
        $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma Q(s', a') - Q(s, a)]$
        $s \leftarrow s'$; $a \leftarrow a'$;
    until s is terminal

[Sutton & Barto, 1998]

ALGORITMO *Q-LEARNING*

Controlo de aprendizagem *Off-Policy*

- Separação entre acção e aprendizagem com políticas específicas
- Aprendizagem utiliza uma política *greedy*
- Acção utiliza uma política ε-*greedy*

Initialize $Q(s, a)$ arbitrarily
Repeat (for each episode):
    Initialize s
    Repeat (for each step of episode):
        Choose a from s using policy derived from Q (e.g., ε-greedy)
        Take action a, observe r, s'
        $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$
        $s \leftarrow s'$;
    until s is terminal

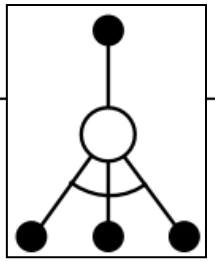

[Sutton & Barto, 1998]

PROCESSO DE APRENDIZAGEM

- **Dois tipos de aprendizagem**
  - **Política de selecção de acção única (*On-policy*)**
    - Utilização da mesma política de selecção de acção para comportamento e para propagação de valor
    - Exploração de todas as acções (e.g. política ε-*greedy*)
  - **Políticas de selecção de acção diferenciadas (*Off-policy*)**
    - Utilização de diferentes políticas de selecção de acção para comportamento e para propagação de valor
    - **Optimização da função valor $Q(s,a)$**

SARSA vs. *Q-LEARNING*

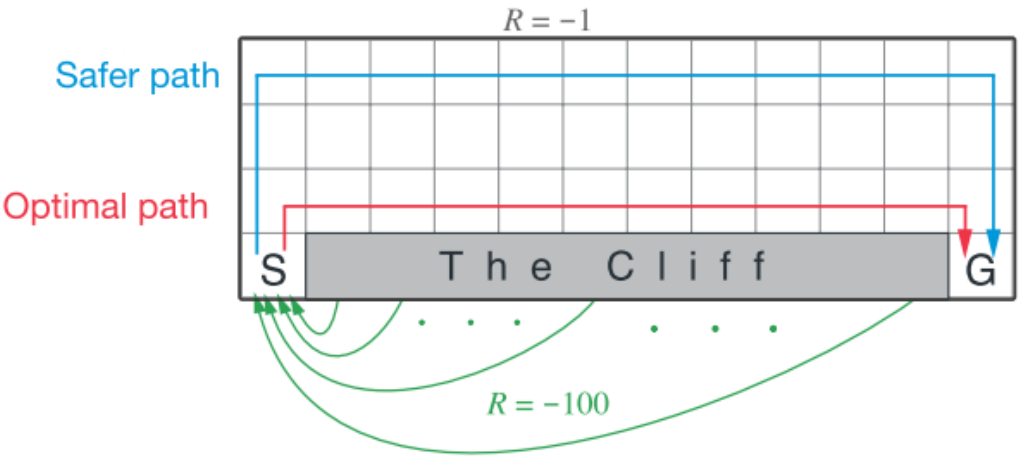

ε–greedy, ε = 0.1

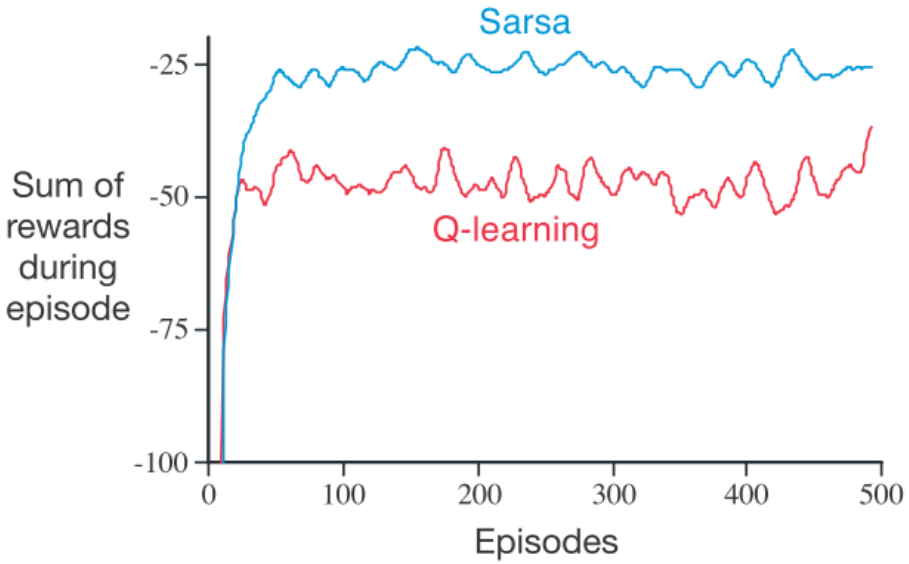

[Sutton & Barto, 2020]

POLÍTICAS COMPORTAMENTAIS

Política Comportamental

- Forma de representação do comportamento do agente
- Estratégia de acção que *define qual a acção que deve ser realizada em cada estado*
- Política **determinista**

$$\pi : S \rightarrow A(s) \; ; \; s \in S$$

- Política **não determinista**

$$\pi : S \times A(s) \rightarrow [0,1] \; ; \; s \in S$$

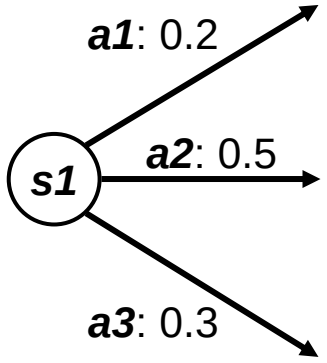

POLÍTICA COMPORTAMENTAL ÓPTIMA

- Função valor de estado-acção

$$Q^{\pi}(s,a)$$

- Valor óptimo

$$Q^{*}(s,a) = \max_{\pi} Q^{\pi}(s,a)$$

- Política óptima

$$\pi^{*}(s) = \arg\max_{a} Q^{*}(s,a)$$

Política "*greedy*" em relação a Q^*

APRENDIZAGEM POR REFORÇO

FORMAÇÃO DE POLÍTICAS COMPORTAMENTAIS

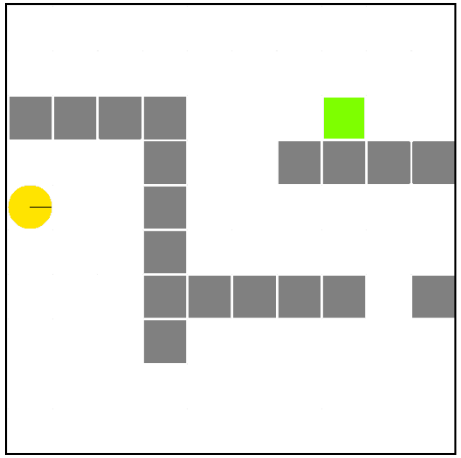

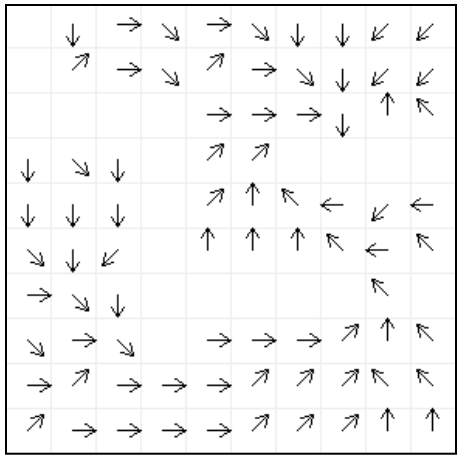

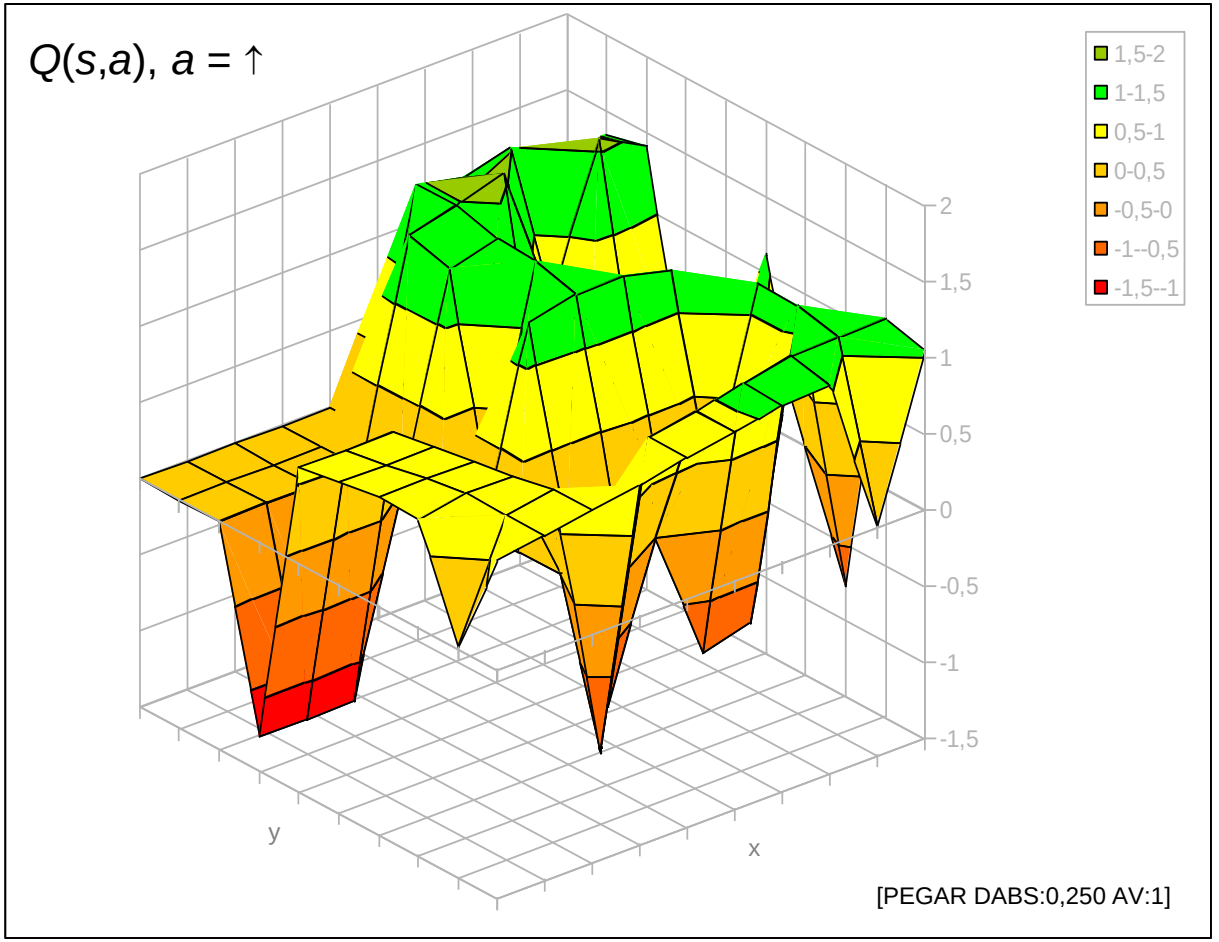

DILEMA EXPLORAR / APROVEITAR

- **Para convergir para o valor óptimo**
  - Não se pode apenas explorar
  - Não se pode apenas aproveitar
- **Estratégia Sôfrega (*Greedy*)**
  - Mínimos/máximos locais
- **Nunca se pode parar de explorar**
  - Convergência assimptótica
- **Deve-se progressivamente reduzir a exploração**
  - GLIE (*Greedy in the Limit of Infinite Exploration)*

ALGORITMO *Q-LEARNING*

- **Propriedades**
  - Os valores da matriz *Q* **convergem** no limite se:
    - Se cada par estado-acção (*s,a*) for visitado um número ilimitado de vezes
    - O parâmetro α tender para 0 no limite
  - No limite a estratégia ε-*greedy* de aproveitamento de *Q*(*s,a*) converge para a **política óptima**

- **Estes requisitos podem ser satisfeitos através de:**
  - $\alpha(s,a) \approx 1/k$
    - Sendo k o número de vezes que a acção ***a*** foi seleccionada em ***s***
  - Estratégia de selecção de acção ε-*greedy* com $\varepsilon \approx 1/t$
    - Sendo ***t*** função do tempo ou do número de tentativas de aprendizagem

APRENDIZAGEM POR REFORÇO

- **PROBLEMAS**
  - Complexidade dos espaços de estados
  - Tempo de convergência
- **SOLUÇÕES**
  - Memória de experiência
  - Utilização de modelos do mundo
  - Generalização / Abstracção
    - Redes neuronais
    - Modelos hierárquicos
  - Arquitecturas híbridas

FORMAS DE ACELERAR A APRENDIZAGEM

Recordar resultado de acções realizadas

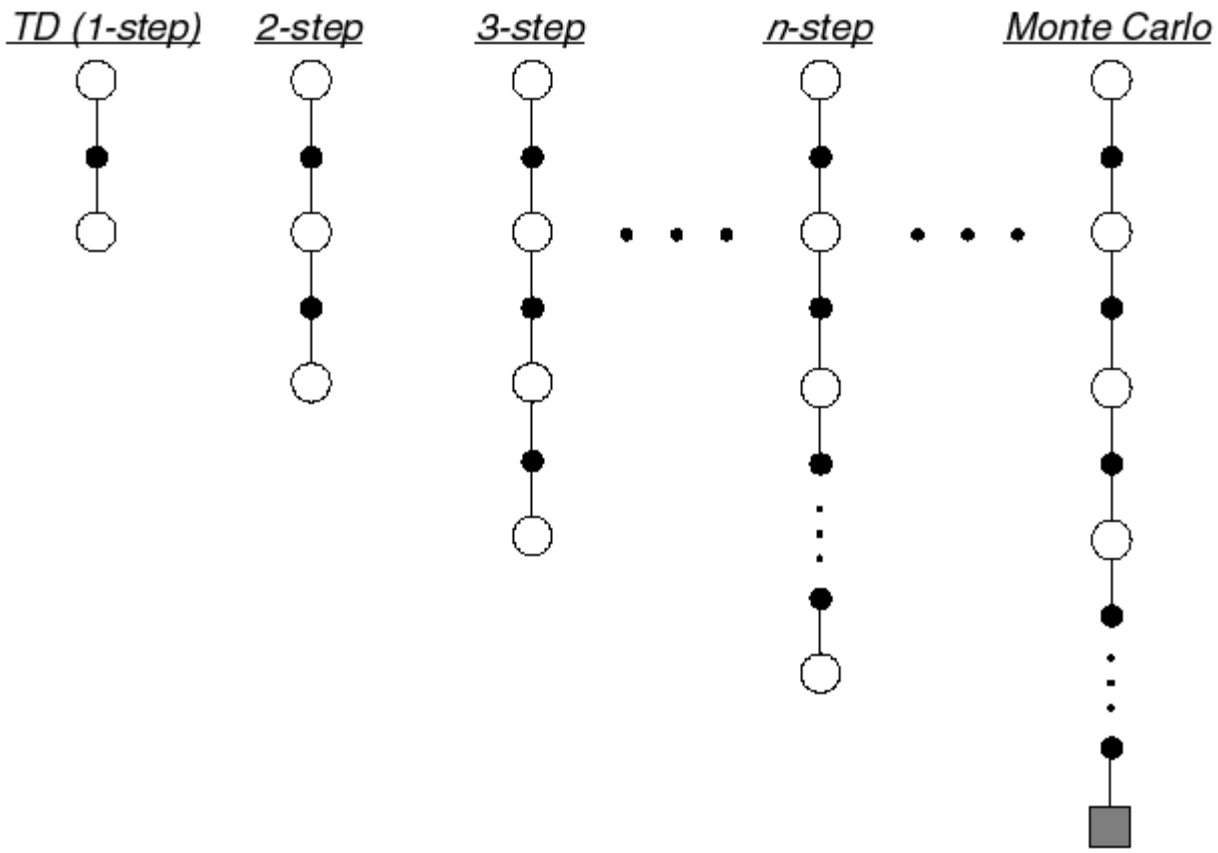

[Sutton & Barto, 1998]

FORMAS DE ACELERAR A APRENDIZAGEM

$\lambda \in [0,1]$ - Return Weighting Function

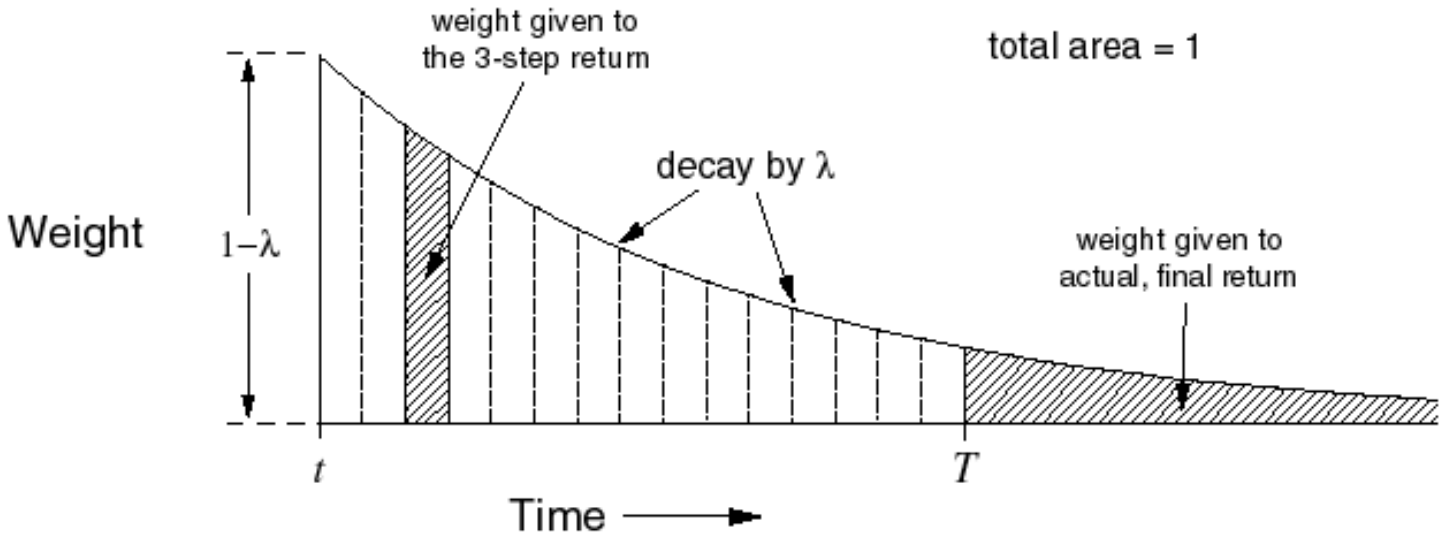

[Sutton & Barto, 1998]

PROPAGAÇÃO DE INFLUÊNCIA

- **RASTO DE ELIGIBILIDADE (*Eligibility Traces*)** $e_t(s) \in \Re^+$
  - ***Accumulating trace*** $$e_t(s) = \begin{cases} \gamma\lambda e_{t-1}(s) & \text{if } s \neq s_t \\ \gamma\lambda e_{t-1}(s) + 1 & \text{if } s = s_t \end{cases}$$
  - ***Replacing trace*** $$e_t(s) = \begin{cases} \gamma\lambda e_{t-1}(s) & \text{if } s \neq s_t \\ 1 & \text{if } s = s_t \end{cases}$$

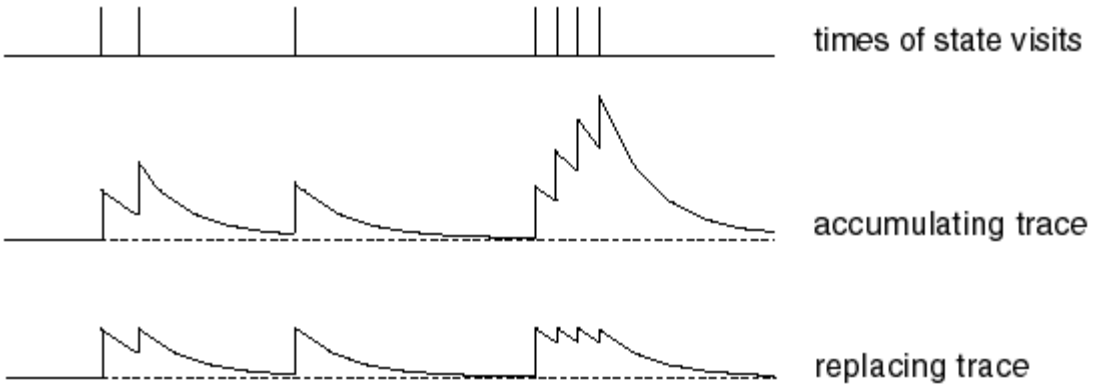

[Sutton & Barto, 1998]

SARSA(λ)

$e(s,a)$ – **Rasto de eligibilidade**

$$\delta_t = r_{t+1} + \gamma Q_t(s_{t+1}, a_{t+1}) - Q_t(s_t, a_t)$$

$$Q_{t+1}(s,a) = Q_t(s,a) + \alpha \delta_t e_t(s,a)$$

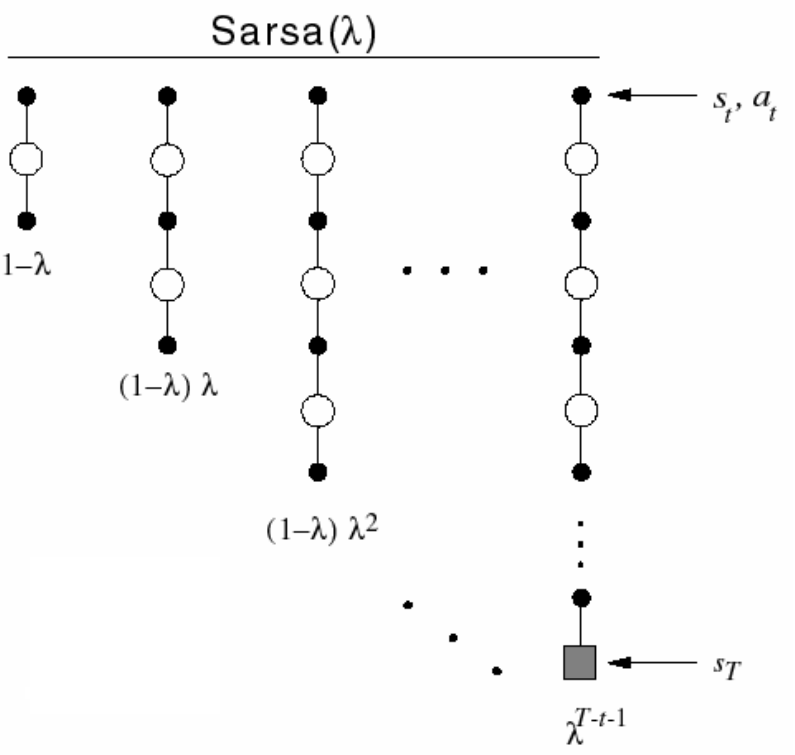

[Sutton & Barto, 1998]

SARSA(λ)

Initialize $Q(s,a)$ arbitrarily

Repeat (for each episode) :

$e(s,a) = 0,$ for all s,a

Initialize s,a

Repeat (for each step of episode) :

Take action $a,$ observe r,s'

Choose a' from s' using policy derived from Q (e.g. ε - greedy)

$\delta \leftarrow r + \gamma Q(s',a') - Q(s,a)$

$e(s,a) \leftarrow e(s,a) + 1$

For all s,a :

$Q(s,a) \leftarrow Q(s,a) + \alpha\delta e(s,a)$

$e(s,a) \leftarrow \gamma\lambda e(s,a)$

$s \leftarrow s'; a \leftarrow a'$

Until s is terminal

[Sutton & Barto, 1998]

SARSA(λ)

Rastros de elegibilidade podem acelerar a aprendizagem

- Mais informação disponível
- Pode **não** ser a melhor!

Exemplo:

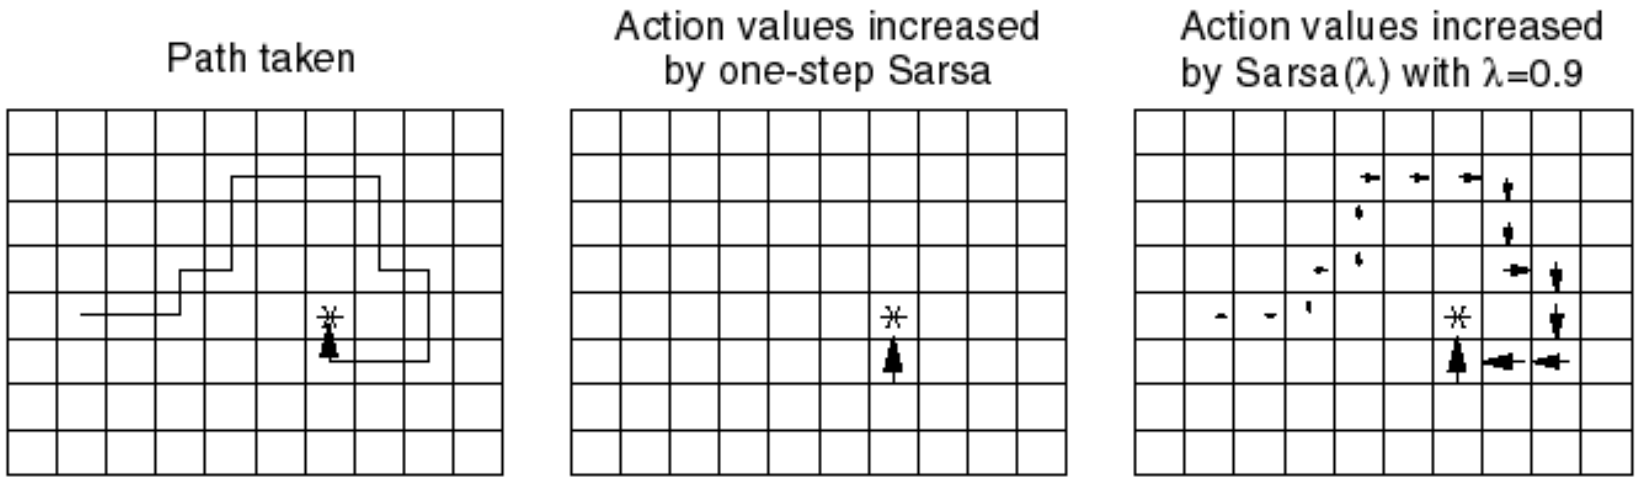

[Sutton & Barto, 1998]

REFERÊNCIAS

[Sutton & Barto, 2020]
R. Sutton, A. Barto, “Reinforcement Learning: An Introduction”, 2nd Edition, MIT Press, 2020

[Poole & Mackworth, 2010]
D. Poole, A. Mackworth, Artificial Intelligence: Foundations of Computational Agents, Cambridge University Press, 2010

[Barnard, 2003]
C. Barnard, “Animal Behaviour: Mechanism, Development, Ecology and Evolution”, Prentice Hall, 2003