APRENDIZAGEM POR REFORÇO

Luís Morgado

ISEL-DEETC

APRENDIZAGEM POR REFORÇO

- **PROBLEMAS**
  - Eficiência do processo de aprendizagem
  - Complexidade dos espaços de estados
- **SOLUÇÕES**
  - Memória de experiência
  - Utilização de modelos do mundo
  - Generalização / Abstracção
    - Redes neuronais
    - Modelos hierárquicos
  - Arquitecturas híbridas

APRENDIZAGEM COM MEMÓRIA DE EXPERIÊNCIA

EXPERIENCE REPLAY

- As experiências do agente são memorizadas numa **memória de experiência** (***replay memory***)
- Num determinado instante ***t,*** a experiência do agente é definida por um tuplo:

$$e_t = (s_t, a_t, r_{t+1}, s_{t+1})$$

- A memória de experiência é utilizada para simular a experiência real
- O objectivo é acelerar o processo de aprendizagem

MEMÓRIA DE EXPERIÊNCIA

REPLAY MEMORY

Experiência real

Memória de experiência

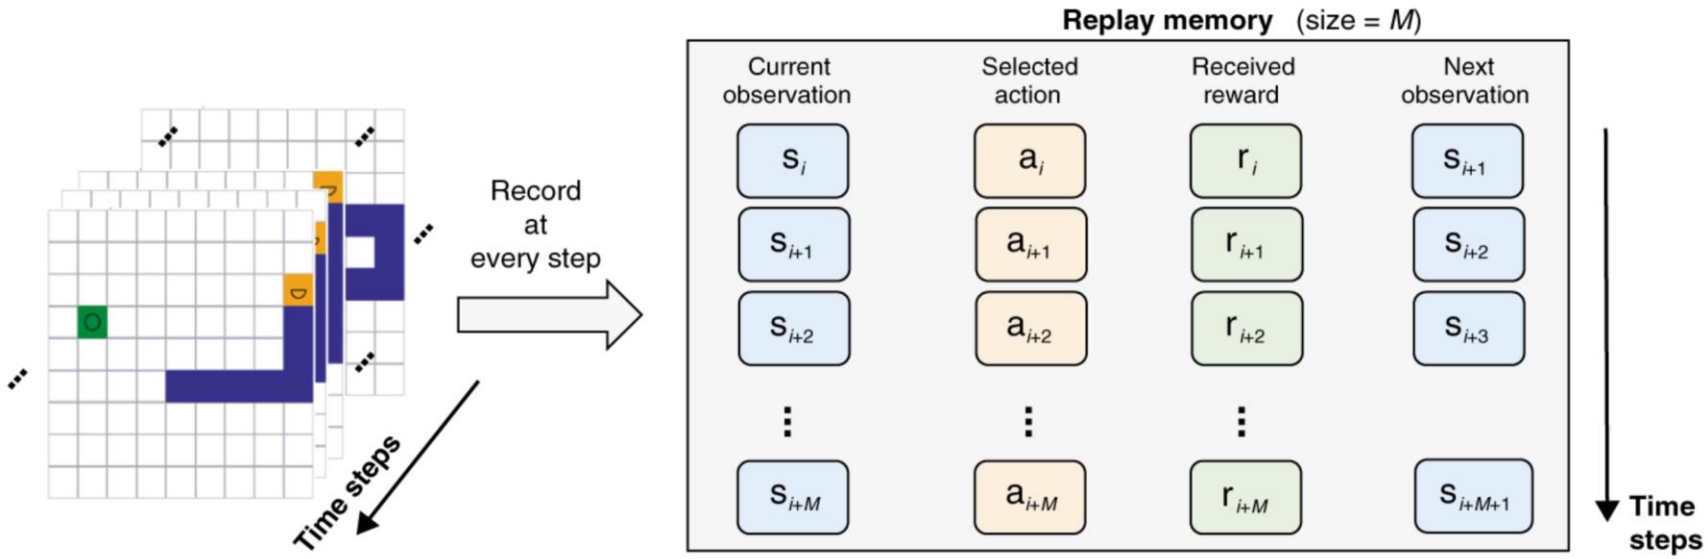

[Cai *et al.*, 2020]

APRENDIZAGEM COM MEMÓRIA DE EXPERIÊNCIA

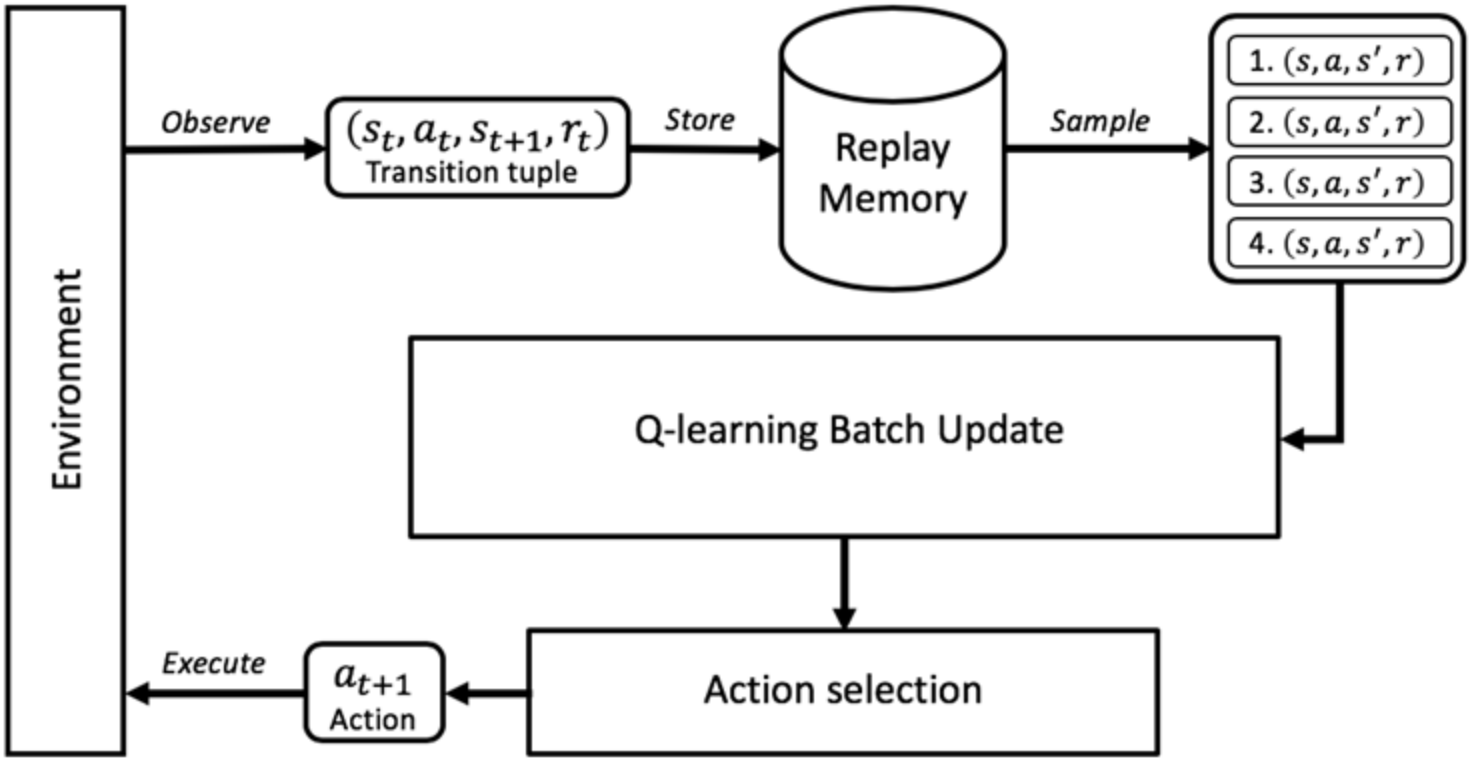

[Raghavan *et al.*, 2019]

Q-LEARNING COM MEMÓRIA DE EXPERIÊNCIA

Initialize $Q(s, a)$ for all $s \in S$ and $a \in A(s)$

Experience Memory $\leftarrow$ {}

Do forever:

$s \leftarrow$ current (nonterminal) state

$a \leftarrow \varepsilon$-greedy(s, Q)

Take action a; observe resultant reward r and state s′

$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_a Q(s', a') - Q(s, a)]$

$e_t = (s, a, r, s')$

Update Experience Memory for experience e_t

Repeat *n* times:

$s, a, r, s' \leftarrow$ sample from Experience Memory

$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_a Q(s', a') - Q(s, a)]$

APRENDIZAGEM COM MEMÓRIA DE EXPERIÊNCIA

- Aspectos a considerar
  - **Dimensão da memória de experiência**
    - Necessário limitar
      - Remover experiências mais antigas
      - Remover por critério de menor relevância
  - **Selecção de amostras**
    - Aleatória (distribuição uniforme)
    - Por critério de relevância
      - Amostragem com prioridade

APRENDIZAGEM COM MODELOS

MODEL-BASED REINFORCEMENT LEARNING

- Aprendizagem de um modelo do mundo
  - **Modelo do mundo**: Representação das características relevantes do domínio do problema
    - **Estrutura** (estado)
    - **Dinâmica** (transição de estado)
    - **Valor** (recompensa)
- Modelo do mundo
  - Utilizado para simular experiência
  - Suporta planeamento
- Necessidade de manter o modelo do mundo actualizado e consistente com a experiência

MODELO DO MUNDO

REPRESENTAÇÃO DO MUNDO

S – conjunto de estados do mundo

$A(s)$ – conjunto de acções possíveis no estado $s \in S$

$T(s,a,s')$ – probabilidade de transição de s para s' através de a

$R(s,a,s')$ – retorno esperado na transição de s para s' através de a

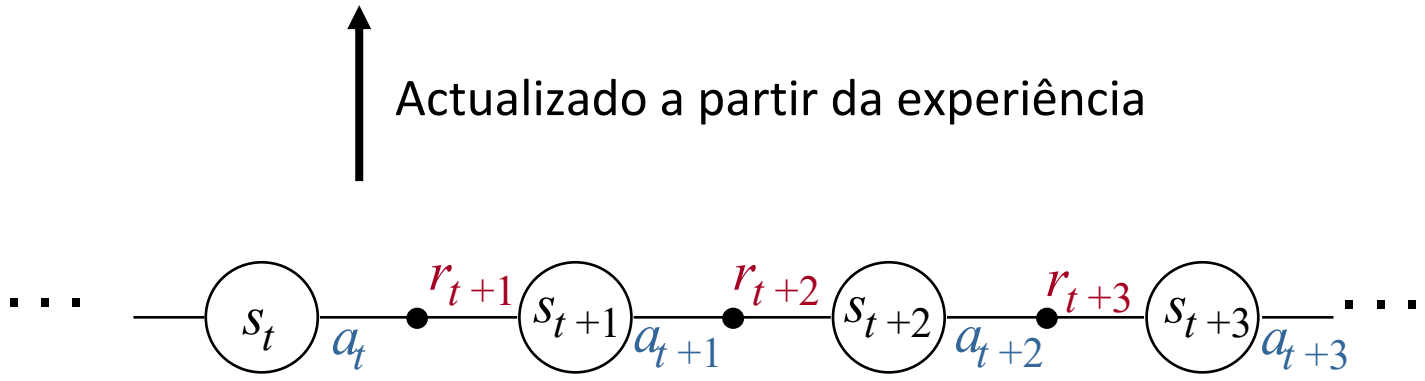

APRENDIZAGEM COM MODELO DO MUNDO

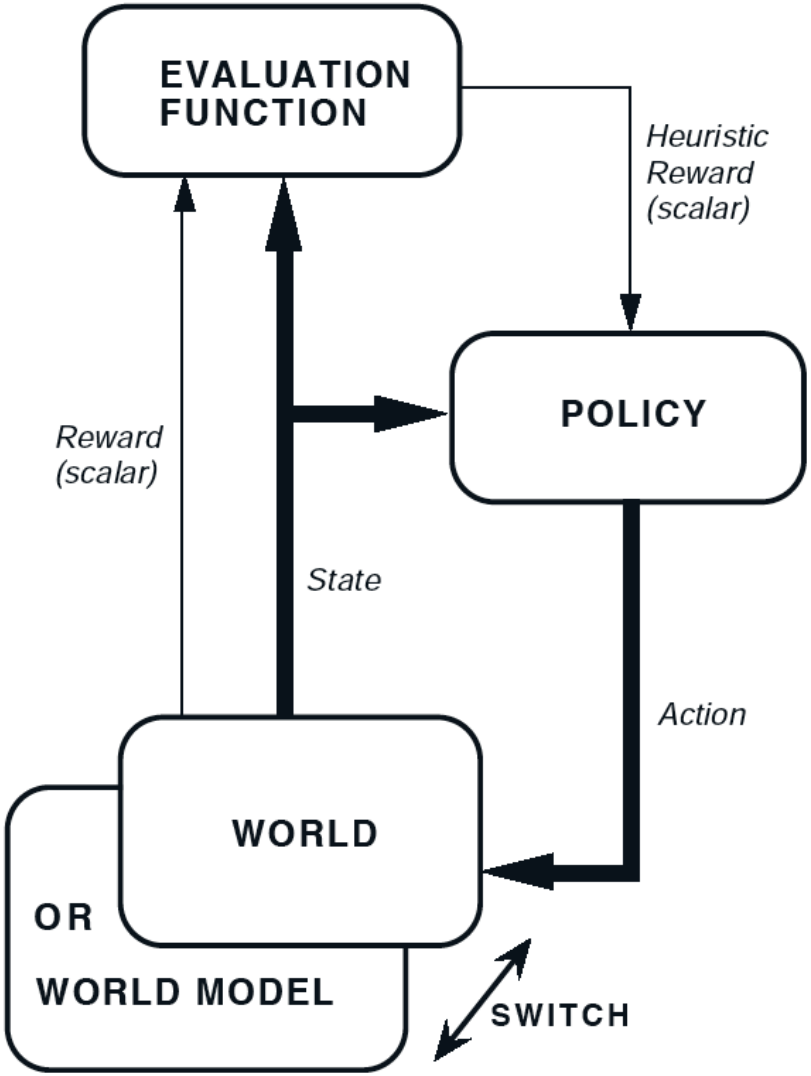

Sutton, 1990

APRENDIZAGEM E PLANEAMENTO

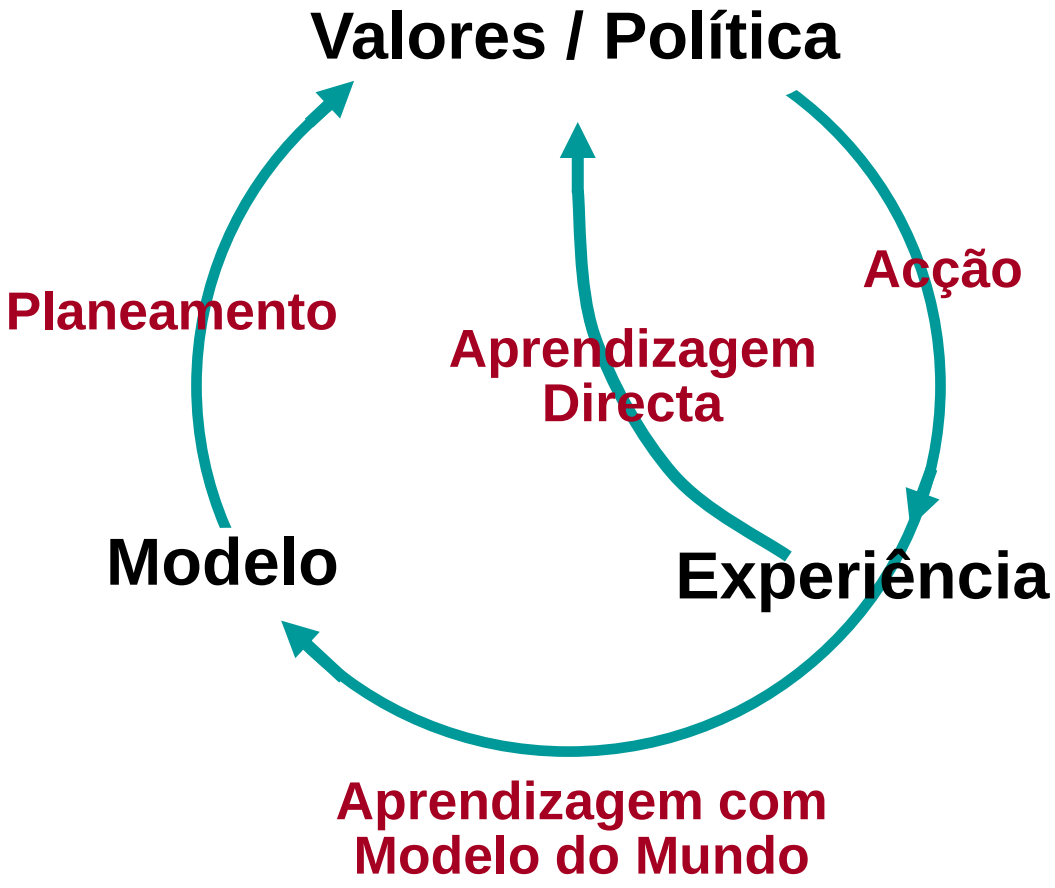

[Sutton & Barto, 1998]

APRENDIZAGEM E PLANEAMENTO

- **EXPERIÊNCIA**
  - Aprendizagem de modelos do ambiente
  - Aprendizagem de valores e políticas de acção
- **PLANEAMENTO**
  - Simulação da experiência
  - Aprendizagem indirecta a partir de modelos internos
  - Iteração de comportamentos, não possível directamente no ambiente

ARQUITECTURA DYNA

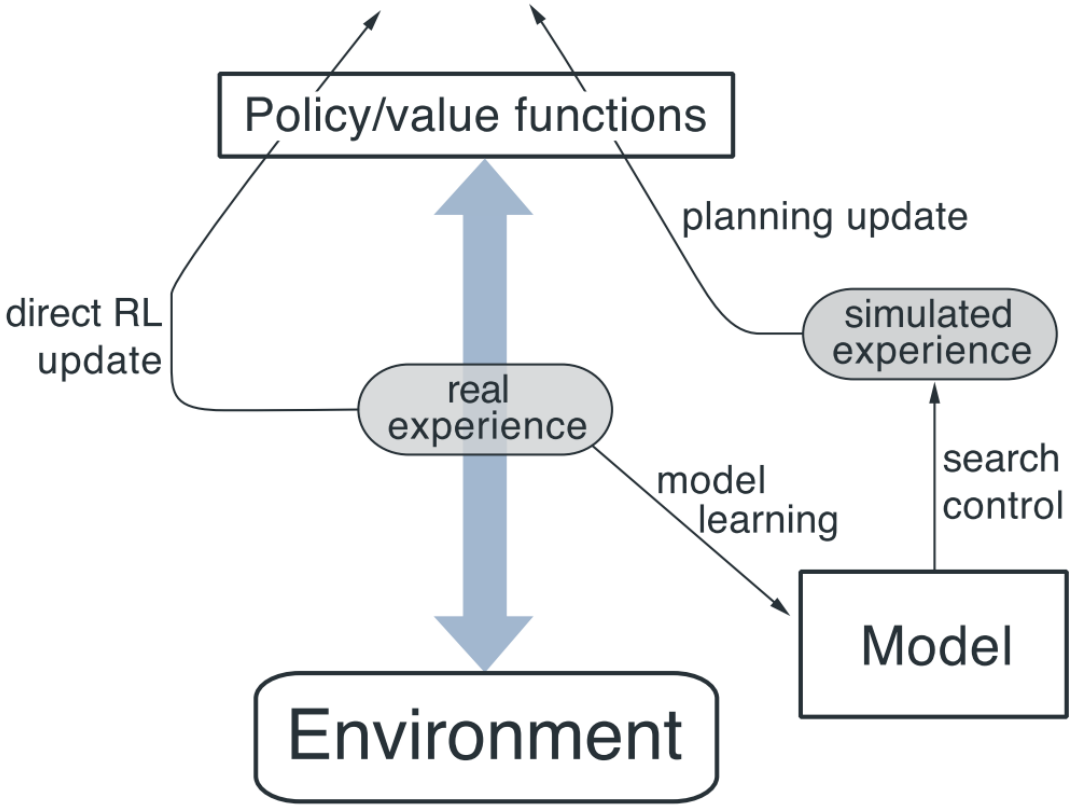

[Sutton & Barto, 2020]

ALGORITMO DYNA-Q

AMBIENTES DETERMINISTAS

$$Model(s,a) = \begin{cases} S \\ A \\ \hat{T}(s,a) \\ \hat{R}(s,a) \end{cases}$$

$$T: S \times A \rightarrow S$$
$$R: S \times A \rightarrow \mathbb{R}$$

$$\hat{T}(s,a) = s'$$
$$\hat{R}(s,a) = r$$

AMBIENTES NÃO DETERMINISTAS

$$Model(s,a) = \begin{cases} S \\ A \\ \hat{T}(s,a,s') \\ \hat{R}(s,a) \end{cases}$$

$$T: S \times A \times S \rightarrow [0,1]$$

$$\hat{T}(s,a,s') = \frac{\text{Number of (s, a, s') experiences}}{\text{Number of (s, a) experiences}}$$

$$\hat{R}(s,a) = \frac{\text{Sum of rewards received by taking action a in state s}}{\text{Number of (s, a) experiences}}$$

ALGORITMO DYNA-Q

Initialize $Q(s,a)$ and $Model(s,a)$ for all $s \in \mathcal{S}$ and $a \in \mathcal{A}(s)$

Do forever:

(a) $s \leftarrow$ current (nonterminal) state

(b) $a \leftarrow \varepsilon$-greedy(s,Q)

(c) Execute action a; observe resultant state, s', and reward, r

(d) $Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$

(e) $Model(s,a) \leftarrow s', r$ (assuming deterministic environment)

(f) Repeat N times:

$s \leftarrow$ random previously observed state

$a \leftarrow$ random action previously taken in s

$s', r \leftarrow Model(s,a)$

$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$

[Sutton & Barto, 1998]

ALGORITMO DYNA-Q

EXEMPLO

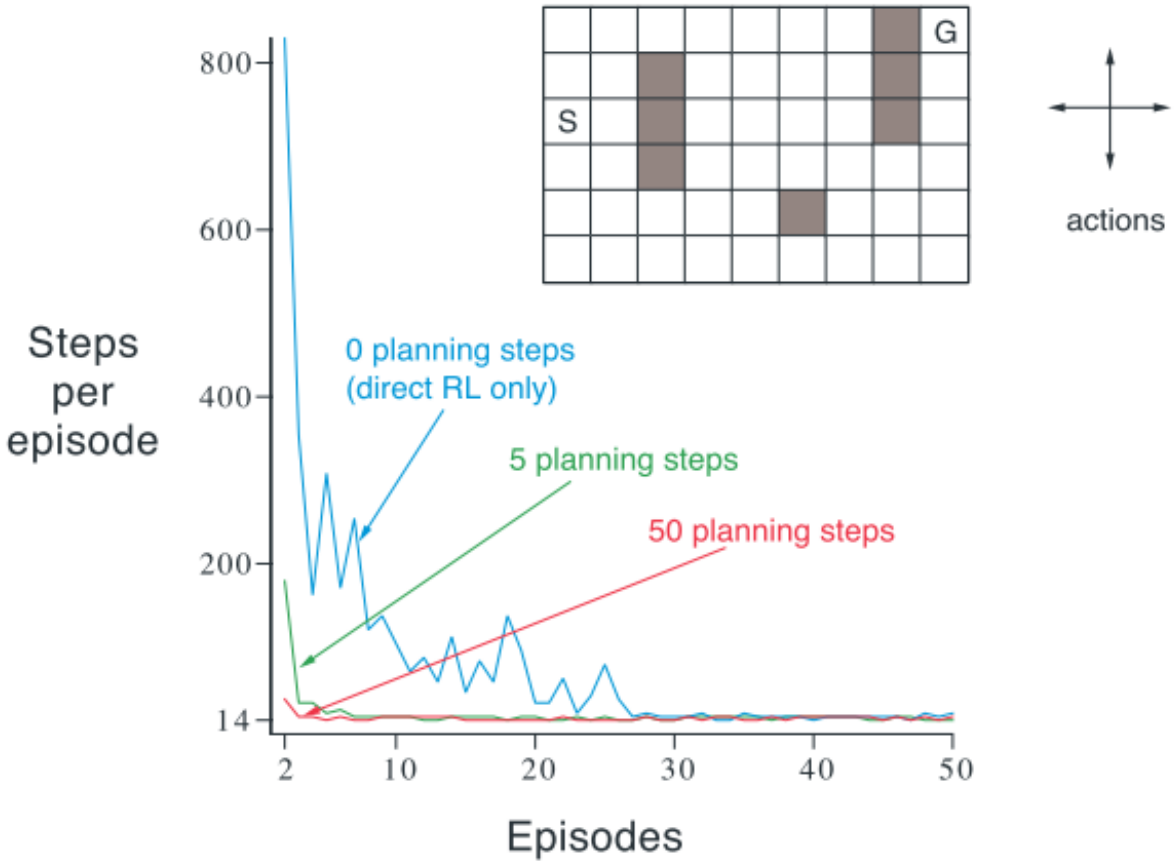

[Sutton & Barto, 2020]

ALGORITMO DYNA-Q

EXEMPLO

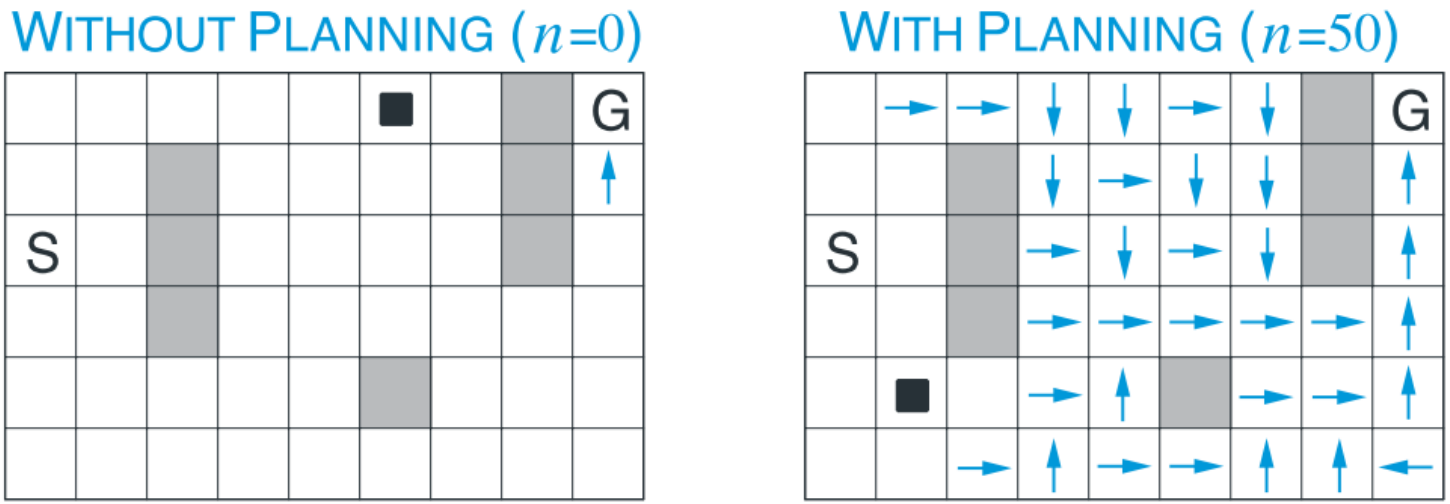

[Sutton & Barto, 2020]

AMOSTRAGEM POR PRIORIDADE

Varrimento com prioridade (*Prioritized Sweeping*)

- **Aumentar a eficiência do planeamento**
  - Simulações e actualizações de valor de pares estado-acção específicos
  - Prioridade a pares estado-acção com grande variação de valor
  - Actualização de valor retrospectiva
    - Pares estado-acção que levam a outros pares estado-acção com grande variação de valor
    - Varrimento de encadeamentos de transições

AMOSTRAGEM POR PRIORIDADE

Varrimento com prioridade (*Prioritized Sweeping*)

Prioritized sweeping for a deterministic environment

Initialize $Q(s,a)$, $Model(s,a)$, for all s,a, and $PQueue$ to empty
Loop forever:
- (a) $S \leftarrow$ current (nonterminal) state
- (b) $A \leftarrow policy(S,Q)$
- (c) Take action A; observe resultant reward, R, and state, S'
- (d) $Model(S,A) \leftarrow R, S'$
- (e) $P \leftarrow |R + \gamma \max_a Q(S',a) - Q(S,A)|$.
- (f) if $P > \theta$, then insert S,A into $PQueue$ with priority P
- (g) Loop repeat n times, while $PQueue$ is not empty:
  - $S,A \leftarrow first(PQueue)$
  - $R,S' \leftarrow Model(S,A)$
  - $Q(S,A) \leftarrow Q(S,A) + \alpha\big[R + \gamma \max_a Q(S',a) - Q(S,A)\big]$
  - Loop for all $\bar{S},\bar{A}$ predicted to lead to S:
    - $\bar{R} \leftarrow$ predicted reward for $\bar{S},\bar{A},S$
    - $P \leftarrow |\bar{R} + \gamma \max_a Q(S,a) - Q(\bar{S},\bar{A})|$.
    - if $P > \theta$ then insert $\bar{S},\bar{A}$ into $PQueue$ with priority P

[Sutton & Barto, 2020]

AMOSTRAGEM POR PRIORIDADE

Varrimento com prioridade (*Prioritized Sweeping*)

Exemplo

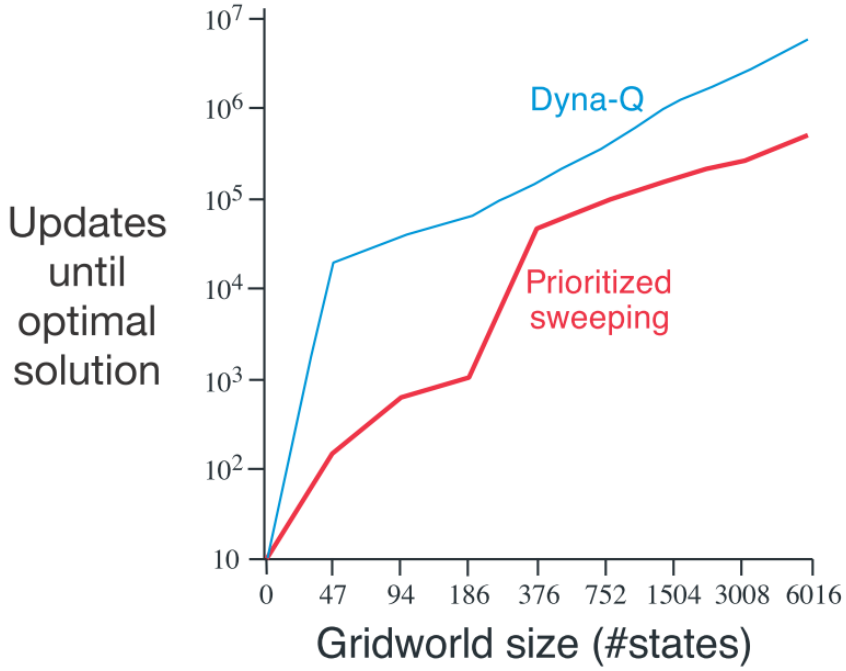

[Sutton & Barto, 2020]

Sistema de recomendação de notícias

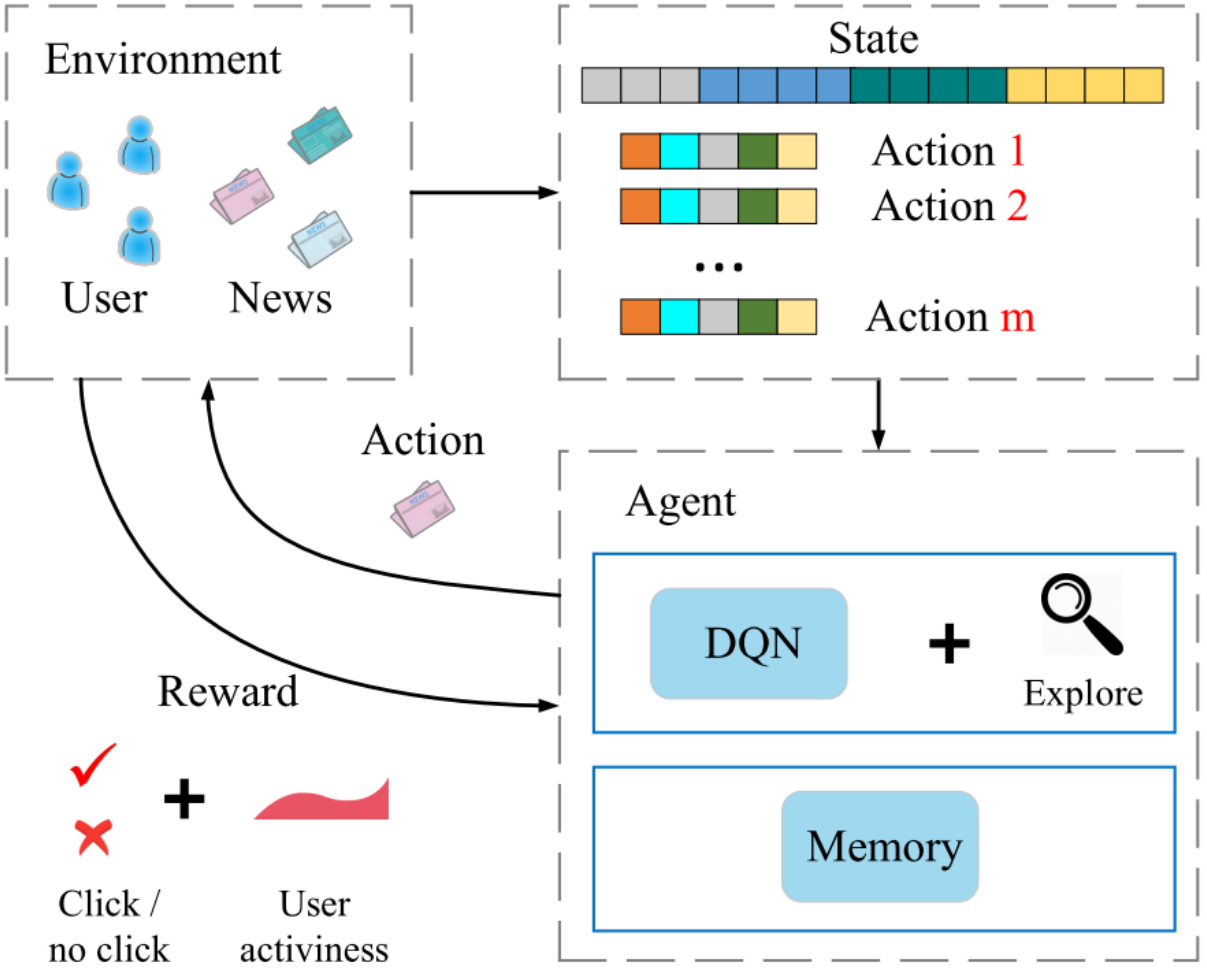

[Zheng *et al.*, 2018]

REFERÊNCIAS

[Russel & Norvig, 2003]
S. Russell, P. Norvig, “Artificial Intelligence: A Modern Approach”, 2nd Edition, Prentice Hall, 2003

[Sutton & Barto, 1998]
R. Sutton, A. Barto, “Reinforcement Learning: An Introduction”, MIT Press, 1998

[Poole & Mackworth, 2010]
D. Poole, A. Mackworth, “Artificial Intelligence: Foundations of Computational Agents”, Cambridge University Press, 2010

[Raghavan *et al.*, 2019]
A. Raghavan, J. Hostetler, S. Chai, “Generative Memory for Lifelong Reinforcement Learning”, 2019

[Cai *et al.*, 2020]
S. Cai, S. Bileschi, E. Nielsen, F. Chollet, “Deep Learning with JavaScript: Neural networks in TensorFlow.js”, Manning Publications, 2020

[Zheng *et al.*, 2018]
G. Zheng, F. Zhang, Z. Zheng, Y. Xiang, N. Yuan, X. Xie, Z. Li, “DRN: A Deep Reinforcement Learning Framework for News Recommendation”, WWW '18: Proceedings of the World Wide Web Conference, 2018