

# **RACIOCÍNIO AUTOMÁTICO PARA OPTIMIZAÇÃO**

Luís Morgado

ISEL-DEETC

# OPTIMIZAÇÃO

- **Seleccção da melhor opção a partir de um conjunto de opções possíveis** de acordo com um critério de avaliação de opções
  - Maximização
  - Minimização
- **Critério de avaliação**
  - Medida de ganho (*performance*)
  - Medida de perda (*loss*)
  - Medida de adequação (*fitness*)

# OPTIMIZAÇÃO

## Definição formal

$A$  – Conjunto de opções possíveis

$f$  – Função de avaliação (define critério de avaliação)

$$f: A \rightarrow \mathbb{R}$$

$$\mathbf{x}_0 \in A$$

$$f(\mathbf{x}_0) \geq f(\mathbf{x}) \quad \forall \mathbf{x} \in A$$


$$f(\mathbf{x}_0) \leq f(\mathbf{x}) \quad \forall \mathbf{x} \in A$$

# OPTIMIZAÇÃO

## Exemplo

$$z = f(x, y) = -(x^2 + y^2) + 4$$

Máximo global:  $(x, y) = (0, 0)$ ,  $z = 4$

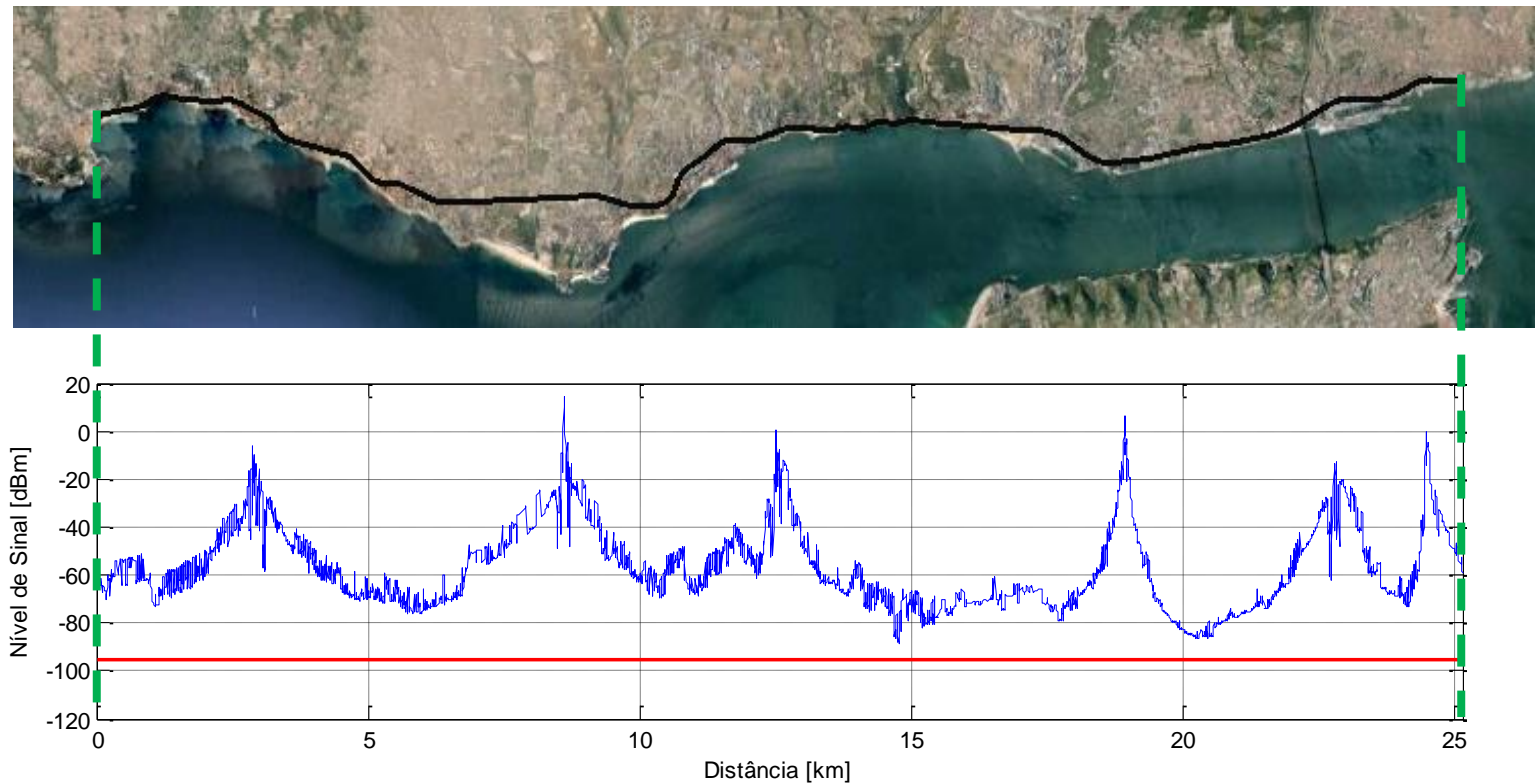


# OPTIMIZAÇÃO


- **Métodos computacionais de otimização**
  - **Otimização matemática**
    - Exemplos
      - Otimização linear
      - Descida de gradiente
  - **Meta-heurísticas**
    - Formas de procura em espaços de estados
    - Exemplos
      - Procura local sôfrega (*Hill-climbing*)
      - Têmpera simulada (*Simulated annealing*)
      - Algoritmos genéticos

# Exemplo: Otimização de Cobertura Rádio

- Otimizar o nível de sinal ao longo da linha através da estimação das estações base necessárias para garantir cobertura em toda a linha




# Exemplo: Otimização de Estruturas



**Fig. 1.** Description of aircraft cabin partition design problem

# Exemplo: Otimização de Estruturas






# OPTIMIZAÇÃO

## CRITÉRIO DE AVALIAÇÃO


$f$  – Função de avaliação



# RACIOCÍNIO AUTOMÁTICO


## RESOLUÇÃO DE PROBLEMAS DE OPTIMIZAÇÃO

- Saber qual a melhor configuração de parâmetros de modo a maximizar uma função de valor ou de adequação
- Resultado: Configuração de parâmetros (estado)



**Procura exaustiva não é viável → Procura local**

# Exemplo: Redes neuronais artificiais



**Configuração:**  $\mathbf{w} = (w_1, w_2)$

↓  
**Estado**


**Vector de transformação  
de estado:**

$$\Delta \mathbf{w} = (\Delta w_1, \Delta w_2)$$

## **Critério de avaliação**

- Medida de ganho (*performance*)

$$P = - \sum_s \left( \sum_z (d_{sz} - o_{sz})^2 \right)$$



# RACIOCÍNIO ATRAVÉS DE PROCURA

## RESOLUÇÃO DE PROBLEMAS DE OPTIMIZAÇÃO

### – Estado

- Representa uma **configuração**
- **Espaço de estados**

### – Transição


- Representa uma **transformação** de estado
  - **Operador** (de transição de estado)
  - **Vector** (de transição de estado)

### – Valor

- Função de valor de estado

### – Solução

- Estado final



# PROCURA EM ESPAÇOS DE ESTADOS LOCAL

## Algoritmo *Hill-Climbing*

```
function HILL-CLIMBING(problem) returns a state that is a local maximum  
  
  current  $\leftarrow$  MAKE-NODE(problem.INITIAL-STATE)  
  loop do  
    neighbor  $\leftarrow$  a highest-valued successor of current  
    if neighbor.VALUE  $\leq$  current.VALUE then return current.STATE  
    current  $\leftarrow$  neighbor
```

**Figure 4.2** The hill-climbing search algorithm, which is the most basic local search technique. At each step the current node is replaced by the best neighbor; in this version, that means the neighbor with the highest VALUE, but if a heuristic cost estimate  $h$  is used, we would find the neighbor with the lowest  $h$ .



# ALGORITMO *HILL-CLIMBING*

## Características

- **Completo**
  - Não é completo
- **Ótimo**
  - Não é ótimo
- **Complexidade**
  - Espacial
    - $O(b)$
  - Temporal
    - $O(d)$


# ALGORITMO *HILL-CLIMBING*

## PROBLEMA: Óptimos Locais



# ALGORITMO *HILL-CLIMBING*

## PROBLEMA: Óptimos Locais



**Figure 4.4** Illustration of why ridges cause difficulties for hill climbing. The grid of states (dark circles) is superimposed on a ridge rising from left to right, creating a sequence of local maxima that are not directly connected to each other. From each local maximum, all the available actions point downhill.



# PROCURA EM ESPAÇOS DE ESTADOS LOCAL

- **Soluções para o problema dos óptimos locais**
  - **Manter memória de estados visitados**
    - Complexidade espacial exponencial
    - **Não é viável para problemas gerais com espaços de estados de grande dimensionalidade**
  - **Mecanismos de exploração não exaustiva**
    - **Amostragem estocástica do espaço de estados**
    - **Controlo de *exploração / aproveitamento***
      - Exploração
        - » Seleccionar operador com um critério de base aleatória
      - Aproveitamento
        - » Gradiente - conhecimento local
        - » Seleccionar operador de seguida de gradiente (acção sôfrega - *greedy*)
  - **Modos de procura**
    - **Modo global**
      - Exploração independente do estado actual (amostragem)
    - **Modo local**
      - Exploração a partir do estado actual (guiada)

# ALGORITMO *HILL-CLIMBING*

## Variantes

- ***Hill-Climbing* estocástico**
  - Escolha aleatória entre sucessores que aumentam o valor de estado
  - Convergência mais lenta que *Hill-climbing*
  - Pode encontrar melhores soluções
    - Consoante a topologia do espaço de estados
  - Não completo
- ***Hill-Climbing* estocástico com único sucessor**
  - Sucessores gerados aleatoriamente até um aumentar o valor de estado
  - Útil quando o número de sucessores por estado é muito elevado
  - Não completo
- ***Hill-Climbing* com reinício aleatório**
  - Procura é reiniciada a partir de estados iniciais aleatórios, até ser atingido um objectivo
  - Completo

# PROCURA EM ESPAÇOS DE ESTADOS LOCAL

- **MÉTODOS DE TÊMPERA SIMULADA** (*Simulated Annealing*)
  - Adaptação dinâmica de parâmetros do método de procura
  - Amostragem
  - Restrição temporal
    - Soluções aproximadas
  - Analogia com a têmpera do metal
    - Aquecimento
      - Flexibilidade
    - Arrefecimento
      - Restrição

# PROCURA EM ESPAÇOS DE ESTADOS LOCAL

## Algoritmo *Simulated Annealing*

**function** SIMULATED-ANNEALING(*problem*, *schedule*) **returns** a solution state

**inputs:** *problem*, a problem

*schedule*, a mapping from time to “temperature”

*current*  $\leftarrow$  MAKE-NODE(*problem*.INITIAL-STATE)

**for**  $t = 1$  **to**  $\infty$  **do**

$T \leftarrow$  *schedule*( $t$ )

**if**  $T = 0$  **then return** *current*

*next*  $\leftarrow$  a randomly selected successor of *current*


$\Delta E \leftarrow$  *next*.VALUE – *current*.VALUE

**if**  $\Delta E > 0$  **then** *current*  $\leftarrow$  *next*

**else** *current*  $\leftarrow$  *next* only with probability  $e^{\Delta E/T}$


**Figure 4.5** The simulated annealing algorithm, a version of stochastic hill climbing where some downhill moves are allowed. Downhill moves are accepted readily early in the annealing schedule and then less often as time goes on. The *schedule* input determines the value of the temperature  $T$  as a function of time.

# ALGORITMO *SIMULATED ANNEALING*



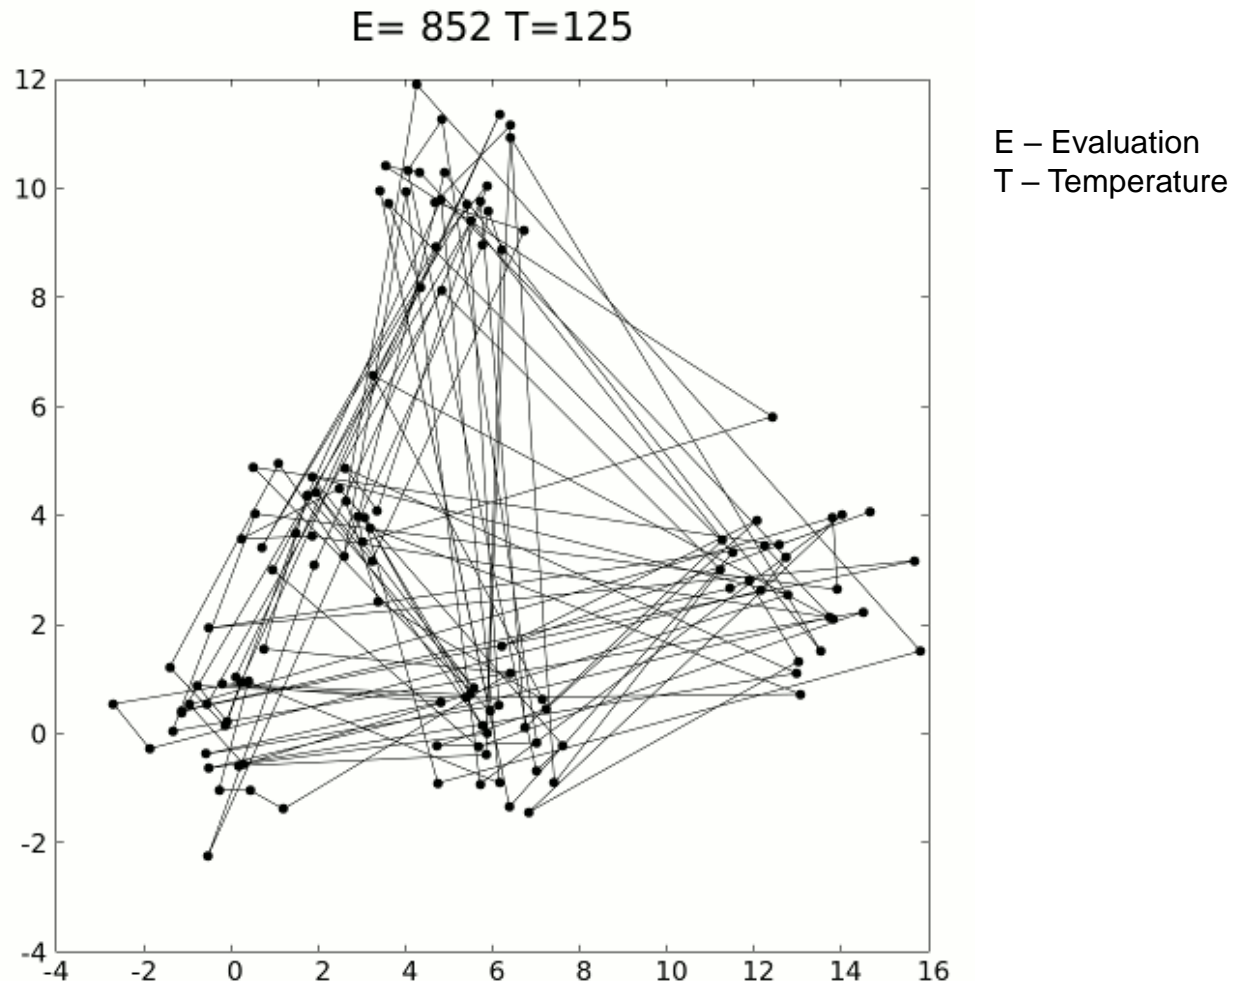
# ALGORITMO *SIMULATED ANNEALING*

## Exemplo



# PROBLEMA DO CAIXEIRO VIAJANTE

Determinar a menor rota para visitar um conjunto de cidades, retornando à cidade de origem



# RESOLUÇÃO DE UM PROBLEMA

## Elementos a considerar na resolução de um problema de otimização

- **Problema**

- Representa informação de contexto do problema
  - e.g. distâncias entre cidades (problema do caixeiro viajante)
- Função de avaliação de estado
- Estado inicial
- Operadores de transformação de estado

- **Estado**

- Representa uma configuração de resolução do problema
  - e.g. configuração de rainhas no tabuleiro (problema das N-Rainhas)
- Realiza encapsulamento de manipulação da configuração de estado



# RESOLUÇÃO DE UM PROBLEMA

- **Operador**

- Representa transformação de estado
- Aplicado a um estado, retorna
  - Um estado sucessor, ou
  - Conjunto de estados sucessores
- Deve produzir transformações locais de estado, reflectindo as características do domínio do problema
  - e.g. movimentação de uma rainha (problema das N-Rainhas)
  - e.g. alteração de sequência parcial do percurso (problema do caixeiro viajante)
- Transformações de estado com carácter aleatório correspondem à introdução de um pendor de amostragem global
  - Degeneram numa procura puramente estocástica
  - Degradação de desempenho

- **Resultados**

- Número de iterações para obter solução
- Qualidade da solução

# REFERÊNCIAS

[Russel & Norvig, 2010]

S. Russell, P. Norvig, “Artificial Intelligence: A Modern Approach”, 3rd Ed., Prentice Hall, 2010

[Beire *et. Al.*, 2014]

A. Beire, N. Cota, H. Pita, A. Rodrigues, “Automatic tuning of Okumura-Hata model on railway communications”, International Symposium on Wireless Personal Multimedia Communications (WPMC), 2014

[Nagy *et al.*, 2018]

D. Nagy, D. Zhao, D. Benjamin, “Nature-Based Hybrid Computational Geometry System for Optimizing Component Structure”, Humanizing Digital Reality, Springer Nature, 2018